

关联规则与 Apriori 算法

大数据金融 · 第 01 次课（90 分钟）

2026 年 10 月

课程定位：第一堂课为什么从关联规则开始

本次课承担的三个作用

01 建立数据到决策的完整闭环
把原始交易流水变成可执行的业务规则，看到数据挖掘完整闭环。

02 引入后续课程的通用词汇
支持度、置信度、提升度，是后续评价指标与特征筛选的基础词汇。

03 给出可完整手算的最小算法
6 ~ 10 条事务即可手工推演每一步，不只调包、真正理解。

金融行业的四类事务型任务

金融业务场景	关联规则的作用
零售银行产品交叉销售	找到「持有 A 的客户常同时持有 B」，指导下一次营销
客户流失预警辅助	发现易流失客户的共同行为组合，供人工复核
银行卡交易模式分析	刻画正常交易组合，为异常交易提供对照
反欺诈与可疑交易线索	输出可疑组合规则，交给人工与合规流程判断

关联规则刻画共现关系，不直接推断因果；课堂示例均为脱敏或构造数据。

本次课目录

01 从购物篮到金融场景

02 三个度量：支持度 · 置信度 · 提升度

03 Apriori 逐层搜索

04 银行产品组合案例

05 参数、读法与业务落地

06 局限、改进与课后任务

银行客户经理如何知道，该向哪类客户推荐哪款产品？

你在电商里见过的「经常一起购买」，就是同一类问题：哪些商品、服务常一起出现？

先看两种朴素做法，各自卡在哪里

做法 A：靠个人经验，谁熟推谁
经验覆盖不了几万客户，客户偏好也随群体变化，无法复核。

做法 B：批量推销，广撒网
成本高、打扰客户，还容易把不合适的产品推给错误的人。

本章要找的答案：从历史交易的共现中，得到可复核、可比较的推荐依据。

购物车分析：从「共现」走到「第三步推荐」

定义：购物车分析（market basket analysis，市场篮子分析）是超市揭示商品间关联的关键技术，找出可一起销售的组合。
背景：顾客常有「冲动购买」，买得比计划多，零售商利用这一倾向做营销。

① 找共现
买面包的人，通常也买黄油

→

② 瞄准客群
锁定同时买面包、黄油的顾客

→

③ 第三品优惠
向其提供鸡蛋折扣，促成第三笔消费

IF **顾客同时购买面包与黄油** THEN **向其提供鸡蛋的折扣优惠**

结果：看到鸡蛋优惠的面包黄油顾客，更倾向于多花些钱买鸡蛋——这就是购物车分析的意义所在。

三步逻辑：先找共现模式，再锁定客群，最后用优惠促成第三笔消费——把随机推销变成基于数据的精准推荐。

金融数据天然是事务型数据：四类任务的映射

一名客户在观察窗口内的产品、一个交易日内的交易，都可以写成一个项集。

金融业务场景	事务的含义	项的含义	关联规则的作用
零售银行产品交叉销售	一名客户的持有产品组合	存款、基金、理财、信用卡、保险	找到「持有 A 常同时持有 B」，指导下次营销
客户流失预警辅助规则	一名客户某一期的行为组合	交易频次下降、理财到期、网银登录减少	发现易流失客户的共同行为组合，供人工复核
银行卡交易模式分析	一笔交易或一名客户一日交易集合	商户类别、金额区间、交易时段	刻画正常交易组合，为异常交易提供对照
反欺诈可疑交易线索	同一账户短期内的交易集合	收款方类型、地域、金额档位	输出可疑组合规则，交人工与合规流程判断

事务口径取决于观察单位：持有组合、一期行为、一日交易是三种常见切法；口径不同，支持度数值不可直接比较，报告须注明口径。

共现≠因果：「持有 A 也持有 B」描述的是相关性，不是「推 A 就能带来 B」的营销因果。

基本概念：项、事务、项集与关联规则

项（item）与项基：最小可分析单元；项基为全部项的集合

事务（transaction）：一名客户观察窗口内的完整持有组合，用 tid 标记；总数 N=6

项集（itemset）：项的任意子集；元素个数记为 |X|，长度为 k 称 k- 项集
例：{存款，基金} 就是一个 2- 项集。

关联规则 X → Y
X、Y ⊆ I，X ∩ Y = ∅，|Y| ≥ 1；
X 为前件，Y 为后件
例：存款 → 保险：持有存款的客户，再推荐保险。

课堂主数据：6 名客户持有产品组合（构造数据）

事务 ID	持有产品组合
T1	存款，基金，保险
T2	存款，基金
T3	基金，保险
T4	存款，保险
T5	存款，基金，保险
T6	基金

阈值：最小支持度 supp_min = 50%（至少出现 3 次）；最小置信度 conf_min = 60%。

度量一 · 支持度：这个组合有多普遍

绝对支持度（计数）

相对支持度（除以事务总数 N）

频繁项集： supp(S) ≥ supp_min 即为频繁项集。本页 supp_min = 50%，即计数至少 3 次。
例：{存款} 出现 4 次，supp = 4/6 ≈ 66.7% ≥ 50%，是频繁项集。

第 1 层 L_1：单项计数（主数据 N=6）

项	计数	支持度	是否保留
存款	4	4/6 ≈ 66.7%	保留
基金	5	5/6 ≈ 83.3%	保留
保险	4	4/6 ≈ 66.7%	保留

三个单项计数都 ≥ 3，全部进入 L_1。支持度回答「这个组合普不普遍」，先把冷门组合筛掉。

度量二 · 置信度：前件成立时，后件有多可信

置信度（条件概率）

前件成立的场合中，规则预测正确的比例；前件不成立的事务不进分母。

高频错误：把分母写成总事务数 N

条件概率 P(Y|X) 的分母是前件 X 的支持度，不是 N。板书时把分母圈出。

错例：误把分母写成 N=6，会把 3/4 错算成 3/6=50%，数值和判定都错。

规则有方向： X→Y 与 Y→X 的分母不同，置信度也不同，不能默认相等。

主数据对照：分母换了，置信度就变

存款 → 基金

前件「存款」计数 4，同时买基金的 3 笔：

基金 → 存款

前件「基金」计数 5，同时存款的 3 笔：

同一对商品，两个方向的置信度分别是 75% 与 60%—— 这就是分母（前件支持度）决定的。

度量三 · 提升度：高置信度就一定有增益吗

提升度（相对独立假设的倍数）

其中 P(Y) = supp(Y)，即后件 Y 的整体支持度。

lift > 1：有前件时后件更常见，正相关

lift = 1：两者相互独立，规则没有增益

lift < 1：有前件时后件更少见，负相关

反例： 90% 置信度，提升度却是 1

1000 名消费者： 500 人买茶叶，其中 450 人同时买咖啡；另外 500 人不买茶叶，其中也有 450 人买咖啡。

咖啡整体占比 = (450+450)/1000 = 90%

结论：高置信度只是「条件下常见」，提升度才回答「比平均多多少」；它是倍数，不是百分点。两者独立，必须分开看。

反例改编自第三方教学材料。

三个度量组成三层筛子：从普遍到可信再到有增益

第一层 · 支持度 supp ≥ 50%
筛掉冷门组合：先只留下普遍出现的项集

↓

第二层 · 置信度 conf ≥ 60%
筛掉不可信规则：前件成立时后件要足够常见

↓

第三层 · 提升度 lift > 1
筛掉高置信度但无增益的规则

强关联规则
同时满足两条：

不满足则为弱关联规则。
例：存款→保险 supp 50%、conf 75%、过前两关即为强规则；lift 1.125 > 1，还有增益。

其他相关性度量：Leverage（取值 [−0.25, 0.25]，可为负：>0 正相关，=0 独立，<0 负相关）与 Conviction（独立假设下的错误预测率 ÷ 实际错误率，规则完全成立时为 ∞）。

先验性质（向下封闭性）：剪枝为什么合法

基本性质：项集扩大，支持度不会上升

正向：一个项集频繁，则它的所有非空子集都频繁。
例：｛存款，基金｝频繁 ⇒｛存款｝、｛基金｝两个子集都频繁。

反向（剪枝依据）：一个项集非频繁，则它的所有超集都非频繁。
例：某个单项低于阈值被删，含它的全部超集不必再计数。

安全剪枝规则

遇到非频繁项集，直接完全跳过它的全部超集，不必访问。

为什么这是效率来源

穷举法要检查全部 2^n-1 个项集； Apriori 用先验性质在计数前就剪掉大批候选，这也是它区别于穷举的关键。

Apriori 全景：两大步，先找频繁项集，再生成规则

第一步 • 频繁项集逐层搜索

① 初始化：扫描一次，统计单项，得 L_1

② 连接： L_{k-1} 自连接生成候选 C_k

③ 剪枝：先验性质删掉含非频繁子集的候选

④ 计数过滤：再扫描得 L_k ，到空层为止

第二步 • 基于置信度生成规则

对每个频繁项集 Z ，枚举它的非空真子集 X 作前件， Y = Z \ X

计算 conf(X→Y) ， ≥ conf_min 才输出为规则

规则生成同样可用先验性质的反向形式：X→Y 不达置信度，后件任何超集对应的规则也不达。

当前位置：已学完三个度量与先验性质，下面用主数据把第一步逐层手算一遍，再进入规则生成。

第 1 次迭代： $C_1 \rightarrow L_1$ ，扫描一次统计单项

输入：主数据 6 条事务（N=6）

事务	持有产品组合
T1	存款，基金，保险
T2	存款，基金
T3	基金，保险
T4	存款，保险
T5	存款，基金，保险
T6	基金

本步动作：候选 C_1 就是全部单项；扫描一遍统计每个单项出现次数，计数 ≥ 3 （50%）即保留。

C_1 计数与过滤（supp_min = 50%）

项	计数	支持度	判定
存款	4	4/6 ≈ 66.7%	保留
基金	5	5/6 ≈ 83.3%	保留
保险	4	4/6 ≈ 66.7%	保留

本步结论： L_1 = {存款，基金，保险}，三项全部保留；下一步由 L_1 连接生成候选 C_2 。

第 2 次迭代： $C_2 \rightarrow L_2$ ， 连接生成两两组合

连接：由 L_1 两两配对，得到 3 个候选 2- 项集

候选：{存款，基金} {存款，保险} {基金，保险}

剪枝检查： 每个候选的 1- 子集（三个单项）都在 L_1 中，没有可剪的候选，全部进入计数。
例：{存款，基金} 的 1- 子集 {存款}、{基金} 都在 L_1 ， 通过检查。

本步结论： L_2 = {{存款，基金}, {存款，保险}, {基金，保险}} ， 三对全部频繁。

计数与过滤（3/6 = 50% 达标）

候选 2- 项集	计数	支持度	判定
{存款，基金}	3	3/6 = 50%	保留
{存款，保险}	3	3/6 = 50%	保留
{基金，保险}	3	3/6 = 50%	保留

三对各出现在 3 条事务中，恰好压在 50% 门槛上；下一步由 L_2 连接尝试生成 3- 项集 C_3 。

第 3 次迭代：C_3 计数不达标，$L_3 = \varnothing$，搜索终止

① 连接
由 L_2 连接得唯一候选
C_3 = { 存款 , 基金 , 保险 }

→

② 子集剪枝
三个 2- 子集都在 L_2，
通过，进入计数

→

③ 计数淘汰
仅 T1 、 T5 同时持有，
计数 2 = 33.3% < 50%

候选 C_3	出现事务	计数	支持度	判定
{ 存款 , 基金 , 保险 }	T1 、 T5	2	2/6 ≈ 33.3%	**丢弃（< 50%）**

循环终止： $L_3 = \varnothing$，没有频繁 3- 项集，无法再向上连接，频繁项集搜索结束。
终止条件：任一层 $L_k = \varnothing$ 即停止，不再生成更高层候选。

频繁项集集合 = $L_1 \cup L_2$
3 个单项 + 3 个 2- 项集，共 6 个频繁项集，供下一步生成规则。

规则生成：对 3 个 2- 项集枚举双向，逐条算置信度

每个频繁 2- 项集 Z，枚举两个方向的非空真子集：前件取其中一项，后件为另一项； conf = supp(Z) ÷ supp(前件)，门槛 conf_min = 60% 。

规则 X → Y	分子 / 分母	支持度	置信度	提升度	判定
存款 → 基金	3 / 4	50%	**75%**	0.9	**lift < 1**
基金 → 存款	3 / 5	50%	**60%**	0.9	**lift < 1**
存款 → 保险	3 / 4	50%	**75%**	1.125	**lift > 1**
保险 → 存款	3 / 4	50%	**75%**	1.125	**lift > 1**
基金 → 保险	3 / 5	50%	**60%**	0.9	**lift < 1**
保险 → 基金	3 / 4	50%	**75%**	0.9	**lift < 1**

「强规则」 = 过了支持度 + 置信度两道门槛；要不要落地，还要看提升度是否大于 1 。

同一张规则表，三种容易读错的读法

读法一 · 项集派生多条规则

本例 3 个频繁 2-项集，每个拆成两个方向，共 6 条规则。

k-项集最多派生 $2^k - 2$ 条规则：k = 2 时 2 条，k = 3 时 6 条，k = 4 时 14 条。

不要以为找到几个频繁项集就只有几条规则。

读法二 · 强规则 ≠ 有增益

6 条全过 conf 门槛，但 4 条 lift = 0.9 < 1，只有存款↔保险两条 lift = 1.125；本数据没有增益明显突出的规则。

过了置信度，还要看提升度才知道是否值得推荐。

读法三 · 规则有方向

存款→基金 conf 75%，反向 基金→存款 只有 60%；前件换方向，置信度要重算，不能照搬。

X→Y 成立不代表 Y→X 同样成立。

三个度量各管一件事：支持度答「常见吗」，置信度答「可信吗」，提升度答「比平均多吗」。

5 笔订单对照：候选剪枝与规则筛选不是一回事

5 笔订单	T1： 1,3,4	T2： 2,3,5	T3： 1,2,3,5	T4： 2,5	T5： 1,3,5

候选剪枝 · 发生在计数之前，对象是项集

前置（计数门槛 2，教师已算好）： L_1 = {1,2,3,5}； L_2 = {{1,3},{1,5},{2,3},{2,5},{3,5}}。

C_3 候选 {1,2,3}、{1,2,5} 都含子集 {1,2}，而 {1,2} 计数仅 1、非频繁。

按先验性质，含非频繁子集的候选不必扫描计数，直接剪掉。

结果： L_3 只保留 {1,3,5}、{2,3,5}

规则筛选 · 发生在置信度阶段，对象是规则

对 {1,3,5} 派生 6 条规则，前 3 条与 {1}→{3,5} 均 ≥ 60% 保留。

{3}→{1,5} conf = 2/4 = 50%、{5}→{1,3} conf = 2/4 = 50%，均 < 60% 拒绝。

这一步只按置信度逐条淘汰；被拒两条的后件已是 2 项，没有更大后件可剪。

{1,2,3} ✂ 含非频繁 {1,2}，剪掉	{1,2,5} ✂ 含非频繁 {1,2}，剪掉	{3}→{1,5} conf 50%，拒绝	{5}→{1,3} conf 50%，拒绝
{1,3,5} 保留入 L_3	{2,3,5} 保留入 L_3	其余 4 条 conf ≥ 60%，保留	

区别：候选剪枝在「找频繁项集」阶段，靠先验性质删项集；规则筛选在「生成规则」阶段，靠置信度删规则。两者对象不同、时机不同，不能互相替代。

伪代码：逐层「连接—剪枝—计数—过滤」直到空层

```
Apriori(T, ε)
  L₁ ← { 长度为 1 的频繁项集 }
  k ← 2
  while L_{k-1} 不为空
    C_k ← Generate_candidates(L_{k-1}, k)
    for 每个事务 t ∈ T
      D_t ← { c ∈ C_k : c ⊆ t }
      for c ∈ D_t : count[c] += 1
    L_k ← { c ∈ C_k : count[c] ≥ ε }
    k ← k + 1
  return 各层 L_k 的并集
Generate_candidates(L, k)：自连接 + 子集全在 L 中才保留
```

最坏复杂度，指数级

n 是项的个数（项基大小），非空项集共 个；时间与空间最坏均为 。

实际开销受四个因素影响

① 最小支持度阈值：阈值越低，频繁项集激增

② 事务总数 N：每层都要全量扫描一遍

③ 平均事务宽度：越宽命中候选越多

④ 项基大小 n：项越多候选空间越大

复杂度的自变量是项数 n，不是输出的项集数量。

Apriori 的五项主要局限

局限	具体说明
多次扫描数据库	每产生一层频繁项集就要完整扫描一次事务集；数据大于内存时，磁盘 I/O 成为瓶颈。
候选集数量爆炸	频繁 1- 项集若有 个，候选 2- 项集理论规模约 ，已在千万量级。
逐层搜索的固有代价	广度优先遍历子集格，发现极大子集 S 前必须先访问它全部 个真子集。
内存开销	候选集及其计数需放入内存；候选集过大时，内存成为瓶颈。
度量本身的局限	支持度 - 置信度筛出的强规则可能只是显而易见的统计规律，也可能因后件高频而误导；提升度可部分缓解，但不能证明因果。

知道局限，才知道什么时候该上 FP-Growth 等更快的算法。

改进方向

四条改进思路（知道思路即可）

① 减少扫描：位向量 / 向量矩阵压缩，一次装载多次复用

② 不生成候选集： FP-Growth 压缩成 FP-Tree ，扫库两次直接挖频繁项集

③ 垂直数据格式： ECLAT 用倒排集合交集求支持度，免扫库

④ 增加度量：提升度、确信度、 χ^2 、Kulczynski 过滤无趣规则

FP-Growth 与 Apriori 的定性对比

维度	FP-Growth	Apriori
模式生成	建 FP-Tree 后挖掘	配对逐层组合
候选集	不生成候选集	依赖候选集
运行时间	更快，近似线性	较慢，项基大时指数增长
内存使用	存数据库压缩版	候选集全存内存

「指数增长」按项数 n 表述，不按输出项集数量。 FP-Growth 、 ECLAT 的完整流程属后续课次。

银行案例：先把长表清洗成 10 条事务清单

业务问题：观察期内哪些产品常被同一客户同时持有，能否作为交叉营销搭配依据？ N = 10， supp_min = 30% （≥ 3 次）， conf_min = 60% 。

预处理四步

① 定观察窗口：只取截止日仍持有（hold_flag=1）的记录

② 清洗：删空记录、去重、剔除 TEST 测试账户、同类子产品合并

③ 口径检查：一名客户只作一条事务，口径须写入报告

④ 转事务清单：按 cust_id 分组聚合为项集

教学构造数据；项基显式给出 5 项，意外险未出现也计入（支持度 0）。

10 条事务（客户 → 持有产品）

客户	持有产品组合
C0001	活期存款，货币基金，银行理财
C0002	活期存款，货币基金
C0003	活期存款，信用卡
C0004	货币基金，银行理财
C0005	活期存款，货币基金，银行理财
C0006	活期存款，银行理财
C0007	活期存款，货币基金
C0008	货币基金
C0009	活期存款，货币基金，信用卡
C0010	活期存款，银行理财

案例逐层：先验把 C_2 从 10 个候选压到 3 个

第 1 层 L_1

项	计数	支持度	判定
活期存款	8	80%	保留
货币基金	7	70%	保留
银行理财	5	50%	保留
信用卡	2	20%	删除
意外险	0	0%	删除

按先验性质，含信用卡、意外险的项集连算都不必算： C_2 由 10 个理论候选直接降到 3 个。

第 2、3 层 C_2/L_2 与 C_3

候选 C_2	计数	支持度	判定
存款，基金	5	50%	保留
存款，理财	4	40%	保留
基金，理财	3	30%	保留

C_3 = { 存款，基金，理财 }： 仅 C0001、C0005 持有，计数 2 = 20% < 30%，丢弃； $L_3 = \varnothing$，搜索终止。

区分「算完被判死」（信用卡）与「根本不是候选」（含信用卡的组合）。

案例规则表： 4 条强规则， 0 条提供增量信息

规则 X → Y	支持度	置信度	提升度	判断
存款 → 基金	50%	5/8 = 62.5%	0.893	强规则， lift<1
基金 → 存款	50%	5/7 ≈ 71.4%	0.893	强规则， lift<1
存款 → 理财	40%	4/8 = 50%	1.0	丢弃（不足 60% ）
理财 → 存款	40%	4/5 = 80%	1.0	强规则， lift=1 独立
基金 → 理财	30%	3/7 ≈ 42.9%	0.857	丢弃（不足 60% ）
理财 → 基金	30%	3/5 = 60%	0.857	强规则， lift<1

核心解读： 80% 的客户本就持有活期存款，后件高频会把置信度天然推高；只看置信度，会把「产品本身普及」误读成「产品之间绑定」。

· 理财 → 存款： conf 80% 全表最高，但 lift = 1.0 ，与全体 80% 的存款普及率相同，二者独立，不能据此做交叉营销。

· 基金 → 存款： lift 0.893 < 1 ，基金客户的存款渗透反而低于平均，不宜反向推荐存款。

使用本案例数据时记住四点

① 10 条记录用于演示流程，不做统计推断

② 结论只反映共现，不含因果方向与时间先后

③ 换事务口径需重算；④ 报告时阈值与规则必须一起给出

最小支持度怎么选：从经验值起步，按结果数量调

第一步 • 选起点

按数据集大小选经验值：
小数据（ <1 万笔）： 0.05–0.1
中等数据（ 1–10 万笔）： 0.01–0.05
大数据（ >10 万笔）： 0.001–0.01

第二步 • 跑一次，看数量

运行 Apriori，看两个数：
频繁项集有多少个?
生成了多少条规则?
目标：人工能复核（ 20–50 条)

第三步 • 按结果调

太多 → 提高阈值（往上收）
太少 / 漏了组合 → 降低阈值
范围合适后，按置信度、提升度筛

最小支持度	频繁项集数	结果意味着什么
0.06	21	合适：人工逐条复核无压力
0.05	31	合适：稍多但可接受
0.02	122	偏多：需脚本先过滤一轮

Groceries 实测： 9,835 笔交易、 169 个品类。支持度从 0.1 往下试， 0.06 出 21 条、 0.05 出 31 条——落在可复核范围，停。再低就爆炸到上百条，不必继续。

置信度与提升度：两步筛选，两个经验值

第一步 · 置信度生成候选

常用 0.6—0.8 。低于 0.5 意味着前件出现时后件不到一半概率，单次营销难以据此决策。

取值越高，留下的规则越少；配提升度过滤后往往所剩无几。

第二步 · 提升度过滤

先按置信度出候选，再只留 lift > 1 。 1.2 是常见起点，不是统计判据。

样本小时 lift 波动大，要看支持度的绝对计数，不能只比倍数。

两个值都要写清取法

报告里要附试算过程与取值理由。只写「按经验设为 0.6 」，评审无法复核，也无法判断结论是否随阈值翻转。

阈值是决策工具，不是装饰。换口径（交易明细 / 客户宽表 / 日期窗口）后，支持度、置信度、提升度都要重新计算。

三个度量测度存在差异

度量	回答的问题	常被误读为
支持度	这个组合有多常见	这个组合有多重要
置信度	有 X 的客户中，多少也有 Y	推荐 Y 后会有多少人买
提升度	比「Y 本来就流行」高出多少	提升了多少百分点

一例读通 • 主数据里的 { 存款 } → { 基金 }

置信度 75%，看似可靠；但基金本身的支持度是 5/6，提升度只有 0.9，低于独立假设。

不加规则、向全体客户推荐基金，命中率为 83.3%，反而高于这条规则的 75%。6 条规则中有 4 条提升度低于 1。

判定顺序：先看支持度是否过门槛，再看置信度，最后一定看提升度。少任何一步，都会把「常见」当成「有效」。

提升度大于 1 只是起点，还要过三道检查

检查一 • 绝对人数

支持度 1% 在 10 万客户里是 1,000 人，可以做；在 200 客户里是 2 人，不能做。

倍数好看不等于有足够的人可以触达。

检查二 • 稳定性

换一个月的数据，提升度是否仍大于 1。

只在一期成立的组合，落地后多半失效。

做法：两期对比，看倍数与人数是否稳定。

检查三 • 可解释性

能否用一句业务语言说清两类产品为什么一起出现。

说不清的规则无法向业务交代，也无法判断效果来自规则还是其他活动。

解释不了，就不要上线。

低支持度的规则不必直接丢

私人银行、家族信托这类小众高价值客户，新兴产品组合，长尾场景，都只在低支持度层出现。

处理方式：单独看提升度、绝对人数与两期对比。只出现过一期、人数是个位数的组合，更像巧合而不是机会。

从规则到动作：四步，顺序不能换

① 筛选

支持度、置信度、提升度设下限。三个值按前两页的方法定，不套固定数字。

② 解读

把 X → Y 翻成一个具体动作。

例：已持有信用卡与基金的客户，在 APP 首页看到意外险入口。

③ 验证

随机分组，触达组与对照组同规模，比较观察期内新增购买。

示例： 1,000 人对 1,000 人。

④ 推广

验证达标后全量推送，保留小比例对照组，监控衰减。衰减到不可接受时回到第 ③ 步重测

四步里只有第 ③ 步能回答「有没有用」。跳过它直接推广，效果无法归因：卖得多了不知道是规则起作用，还是季节性、活动或客群本身在变。

置信度 80%，不等于推销后 80% 的人会买

把 1,000 位 X 持有者拆开

持有 X： 1,000 人
- 已有 Y： 800 人 → 置信度 80%
  - （已买过，推销对他们没用）
- 没有 Y： 200 人 → 只能推销这 200 人
  - 新买： 20 人 → 转化率 10%
    - 不推也买： 10 人
    - **因推才买： 10 人 → 增量**
  - 不买： 180 人

三个比例，答三个问题

置信度：已有 Y/ 已有 X
X 和 Y 常一起出现？ → 80%

转化率：新买 Y/ 触达未持有者
推销后多少人买？ → 10%

增量：触达组−对照组
推销多带来多少？ → 10 人

按 80%×1,000 人估算得 800 人；推销实际带来只有 10 人。
置信度选方向，增量必须用随机对照实验测量。

本章小节

① 三个度量筛规则

支持度看共现频率，置信度看条件概率，提升度判断是否真正正相关。

② 两步算法找频繁项集

Apriori 逐层生成候选 Ck，用先验性质剪枝，留下频繁项集 Lk，再生成规则。

③ 共现 ≠ 因果

规则描述的是相关性，不含时间方向；报告必须同时给出阈值。

④ 参数与落地决定能不能用： 阈值反推、提升度过滤、随机对照验证；置信度不等于转化率。

课后任务

· 练习二： conf_min=90% 下的强规则；阈值降到 33.3% 后 $L_1/L_2/C_3/L_3$ 是否改变；Apriori 三局限 + 改进思路。

· 练习三（选做）：按季度交易事件定义事务与项，比较口径变化。

下次课预告： FP-Growth

Apriori 反复扫描数据库、候选集爆炸； FP-Growth 压缩成 FP-Tree，只扫两次数据库，递归挖掘频繁项集。



谢 谢!

大数据金融 · 第 01 次课：关联规则与 Apriori