

分类算法

2026年08月

本章目录

01 前言
02 kNN算法
03 朴素贝叶斯
04 决策树

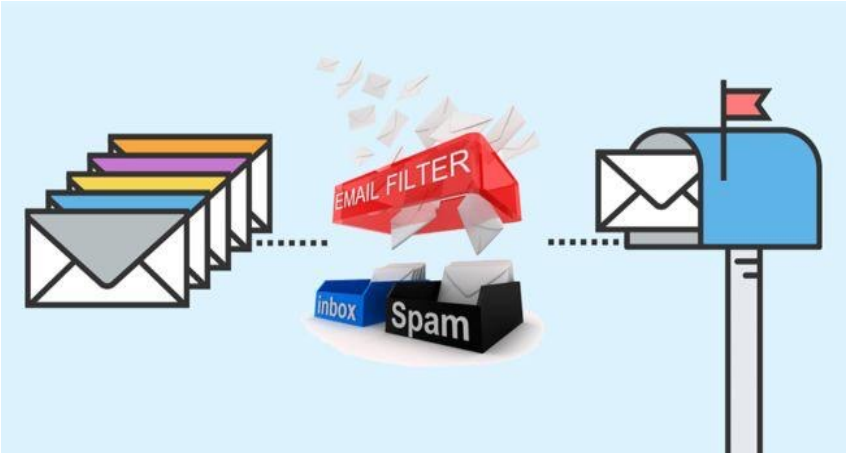
1.前言

- 分类是监督学习的核心问题之一。在分类问题中，数据的输出属性是离散的。

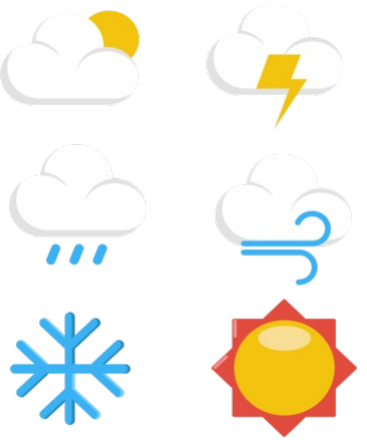
- 当分类的类别是两个时，为二分类问题；当分类的类别大于两个的时候，为多分类问题。

标签离散

邮件分类



天气预测



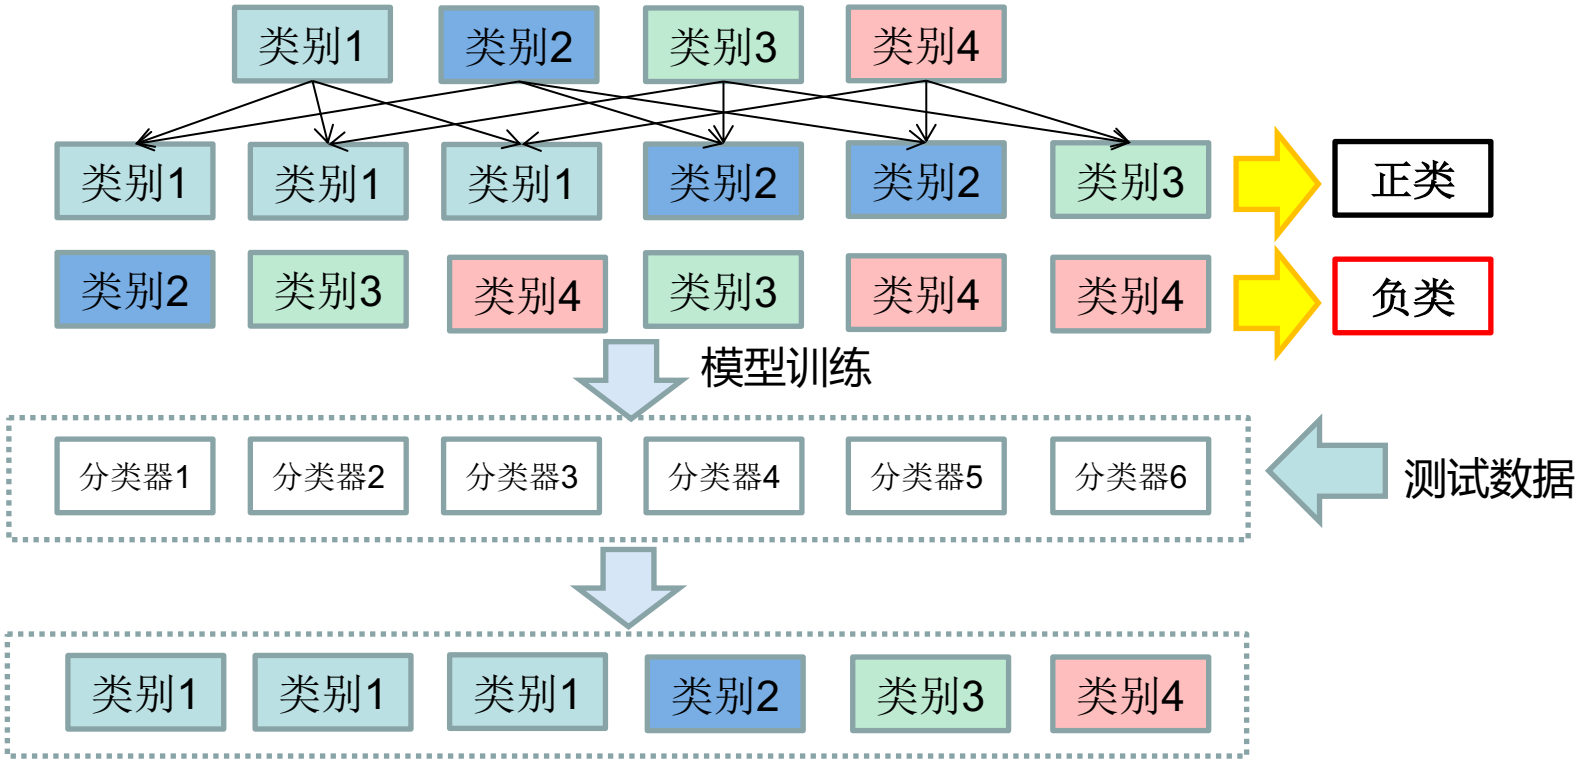
1、前言

- 二分类问题：在二分类问题中，预测输出变量只有两个值，一般情况下，我们用0来表示负类（注：有些书也用-1表示负类），用+1表示正类。对于这种二分类问题，我们只需要构建一个分类器即可。

- 多分类问题：在多分类问题中，输出预测变量则有多个值 $y = \{0,1,2,3,\ldots.\}$

1.前言

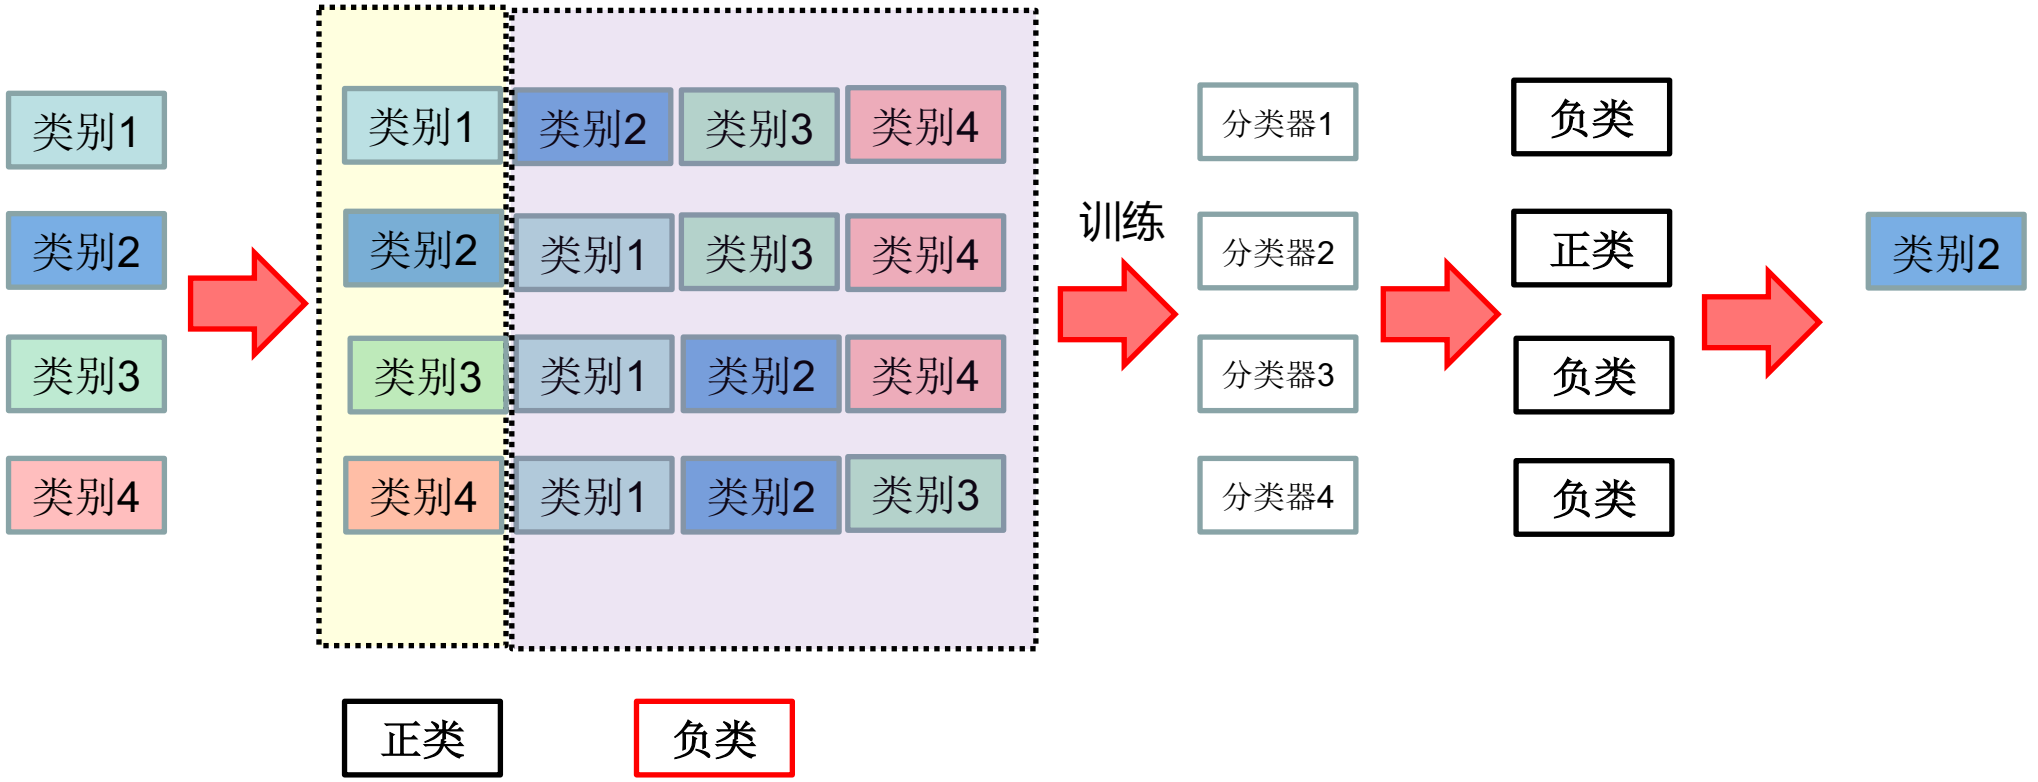
- “一对一”策略（One vs. One）
  - 假定某个多分类问题中有N个类别，我们将这 个类别进行两两配对，就可以将该多分类问题转换成为$\binom{N}{2}$ 个二分类问题。



测试数据被分到类别1

1.前言

- “一对剩余”策略（One vs. Rest）
  - 每次将一个类别作为正类，剩余的所有类别作为负类。



2.kNN算法

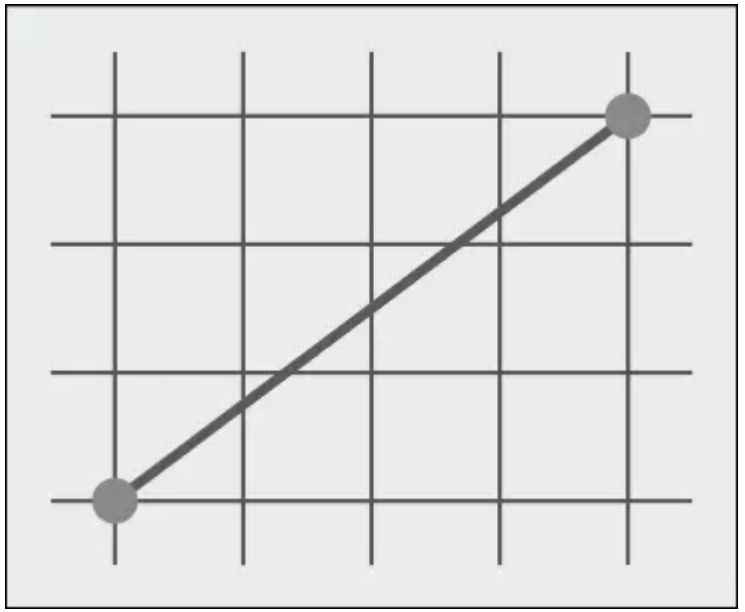
- **k-最近邻算法**（k-Nearest Neighbors, kNN）是最简单、最基础的监督学习算法之一。
- 它的思路是「看邻居」：要预测一个新样本，先在已知标签的样本中找出离它最近的 k 个样本，也就是 k 个「邻居」，再用这些邻居的标签给出预测。
- 距离按样本的特征计算，常用欧氏距离。
- 做分类时，取邻居中最多的类别；做回归时，取邻居数值的平均数。kNN 不需要先训练出一个模型，预测时直接拿新样本和已有样本比较。
-

2.kNN算法

- **常用的距离指标：**
  - 欧几里得距离：

是一个通常采用的距离定义，指在多维欧几里得空间空间中两个点之间的**真实距离**

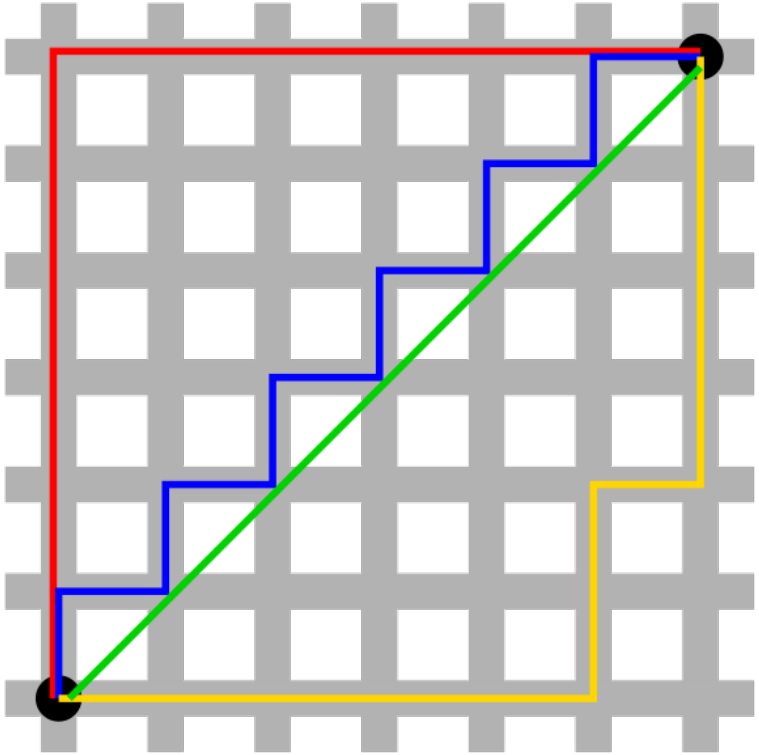
$$d(a,b) = \sqrt{\sum_{k=1}^{n}(x_{1k} - x_{2k})^2}$$



2.kNN算法

- **常用的距离指标：**
  - 曼哈顿距离：
  - 想象你在城市道路里，要从一个十字路口开车到另外一个十字路口，驾驶距离是两点间的直线距离吗？显然不是，除非你能穿越大楼。实际驾驶距离就是这个“曼哈顿距离”。

$$d(a,b) = \sum_{k=1}^{n} |x_{1k} - x_{2k}|$$



2.kNN算法

- **常用的距离指标：**
  - 闵可夫斯基距离：
  - 距离度量的一般化形式

$$d(a,b) = \left(\sum_{k=1}^{n} |x_{1k} - x_{2k}|^{p} \right)^{1/p}$$

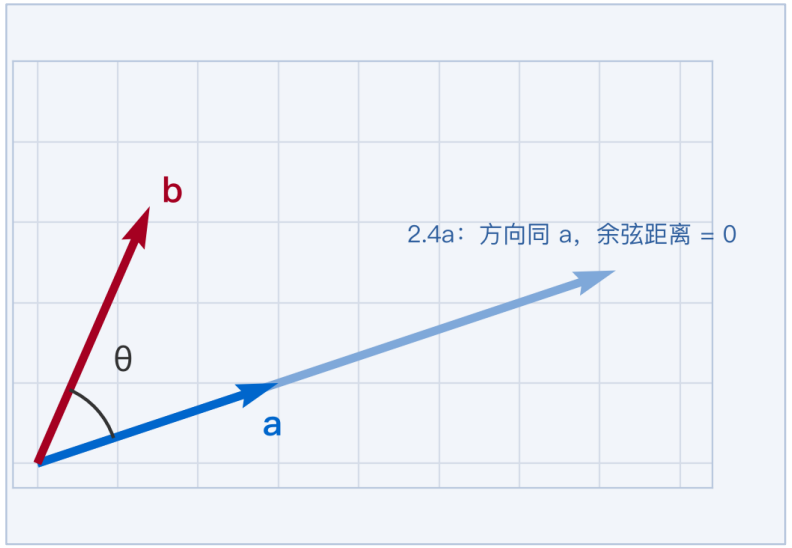
- p=2即为欧氏距离，
- p=1时则为曼哈顿距离。
- 当p取无穷时的极限情况下，可以得到切比雪夫距离

2.kNN算法

- **常用的距离指标：**
  - **余弦距离：**
  - 衡量两个向量的**夹角**：只看方向，不看长度
- θ 越小，cos θ 越接近 1，两个样本越相似
- 余弦距离 = 1 − cos θ，距离越小越相似
- 例：A 持股票 10 万、债券 20 万；B 持股票 100 万、债券 200 万
- 欧氏距离约 201 万，余弦距离为 **0**：两人配置比例相同

$$\cos\theta = \frac{\sum_{k=1}^{n} x_{1k}x_{2k}}{\sqrt{\sum_{k=1}^{n} x_{1k}^2} \cdot \sqrt{\sum_{k=1}^{n} x_{2k}^2}}$$

$$d_{\cos}(a,b) = 1 - \cos\theta$$



2.kNN算法

距离指标汇总：没有最好的距离，按数据形态和业务问题选

距离	公式	衡量什么	适用场景（金融举例）
欧氏距离	$\sqrt{\Sigma(x_{1k}-x_{2k})^2}$	两点间的直线距离；差值先平方，大差值影响更大	**低维、连续、已标准化的特征。**例：按年龄、收入、负债率找相似客户
曼哈顿距离	$\Sigma\lvert x_{1k}-x_{2k}\rvert$	各维差值的绝对值相加；受单个极端差值的影响比欧氏距离小	**特征含异常值或维数较多。**例：用多项财务比率逐项比较企业
切比雪夫距离	$\max_k \lvert x_{1k}-x_{2k}\rvert$	只看差距最大的那一维	**任何一项超标都不能接受。**例：风控限额、逐项合规检查
闵可夫斯基距离	$(\Sigma\lvert x_{1k}-x_{2k}\rvert^p)^{1/p}$	通用形式：p=1 为曼哈顿，p=2 为欧氏，p→∞ 为切比雪夫	**不确定选哪种时，把 p 当超参数，用交叉验证选。**sklearn 的 kNN 默认 p=2
余弦距离	$1-\cos\theta$	两个向量的夹角；只看方向与比例，不看大小	**只关心结构或比例。**例：持仓结构相似度、新闻文本相似度、推荐系统

共同前提：各特征量纲不同时，先标准化，再算距离。余弦距离也受单个特征缩放的影响。

2.kNN算法

分类流程：让最近的 k 个邻居投票

准备：训练样本已有类别；先选好 k 和距离指标。
需要标准化时，用训练集的参数统一处理新样本。

1. 算距离

计算新样本到每个训练样本的距离。

2. 找邻居

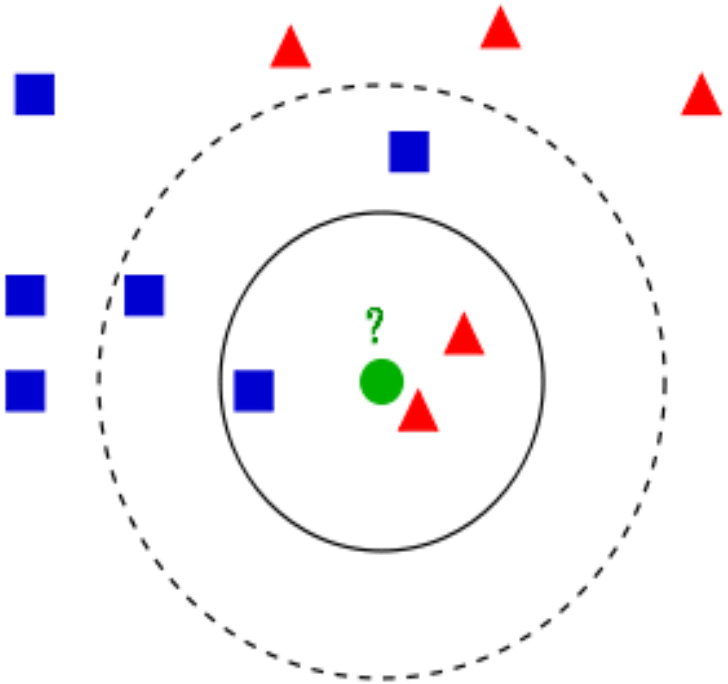
按距离从小到大排序，取最近的 k 个样本。

3. 数票数

每个邻居投一票，统计各类别的票数。

4. 定类别

把票数最多的类别，作为新样本的预测类别。



绿色圆点：待分类的新样本
内圈 k = 3：红 2 票、蓝 1 票 → 红三角类
外圈 k = 5：红 2 票、蓝 3 票 → 蓝方块类

本页采用等权投票。票数相同时，按预先约定的规则处理。

2.kNN算法

选 k：看谁预测验证样本更准确

怎么比较?

① 候选 k：1、3、5

② 每次：64 训练、16 验证

③ 轮流 5 次，算平均

④ 均值最高：k = 3

100 笔：80 笔选 k，20 笔留测

80 笔分成 5 份，每份 16 笔。

同一组 16 笔，分别用不同 k 预测：

候选 k	第 1 轮预测正确	5 轮平均
k = 1	12 / 16	80%
k = 3	**13 / 16**	**85%**
k = 5	14 / 16	82.5%

选 k = 3：5 轮平均正确率最高。

数字为教学示例；选定 k 后，用 80 笔建模，再用 20 笔测试。

2.kNN算法

优点

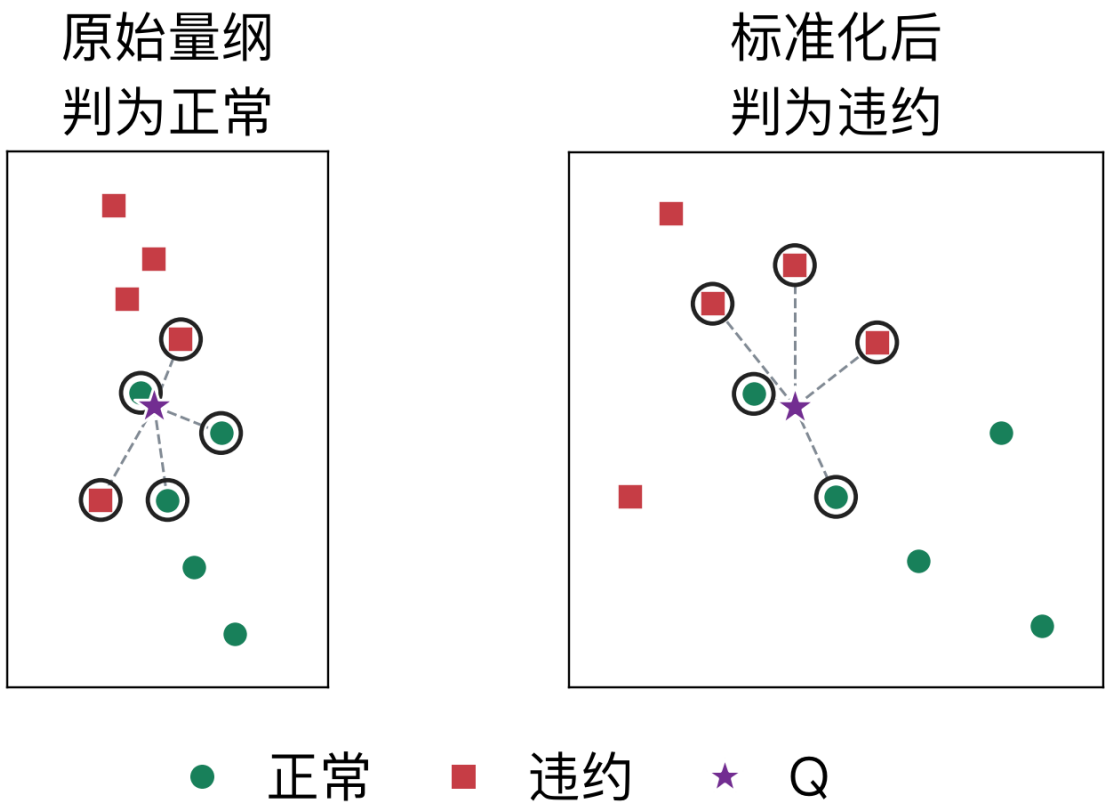
- 思路直观，易于理解和实现。
- 训练阶段主要保存样本，通常较快。
- 新增样本可加入训练集，无须重新拟合参数。

局限

- 数据量大时，存储开销和预测耗时可能增加。
- 对特征尺度、噪声和异常值较敏感。
- 特征过多时距离区分度可能下降，可考虑降维。

尺子变了，邻居就变了

同一客户，k = 5：缩放前后预测结果不同。

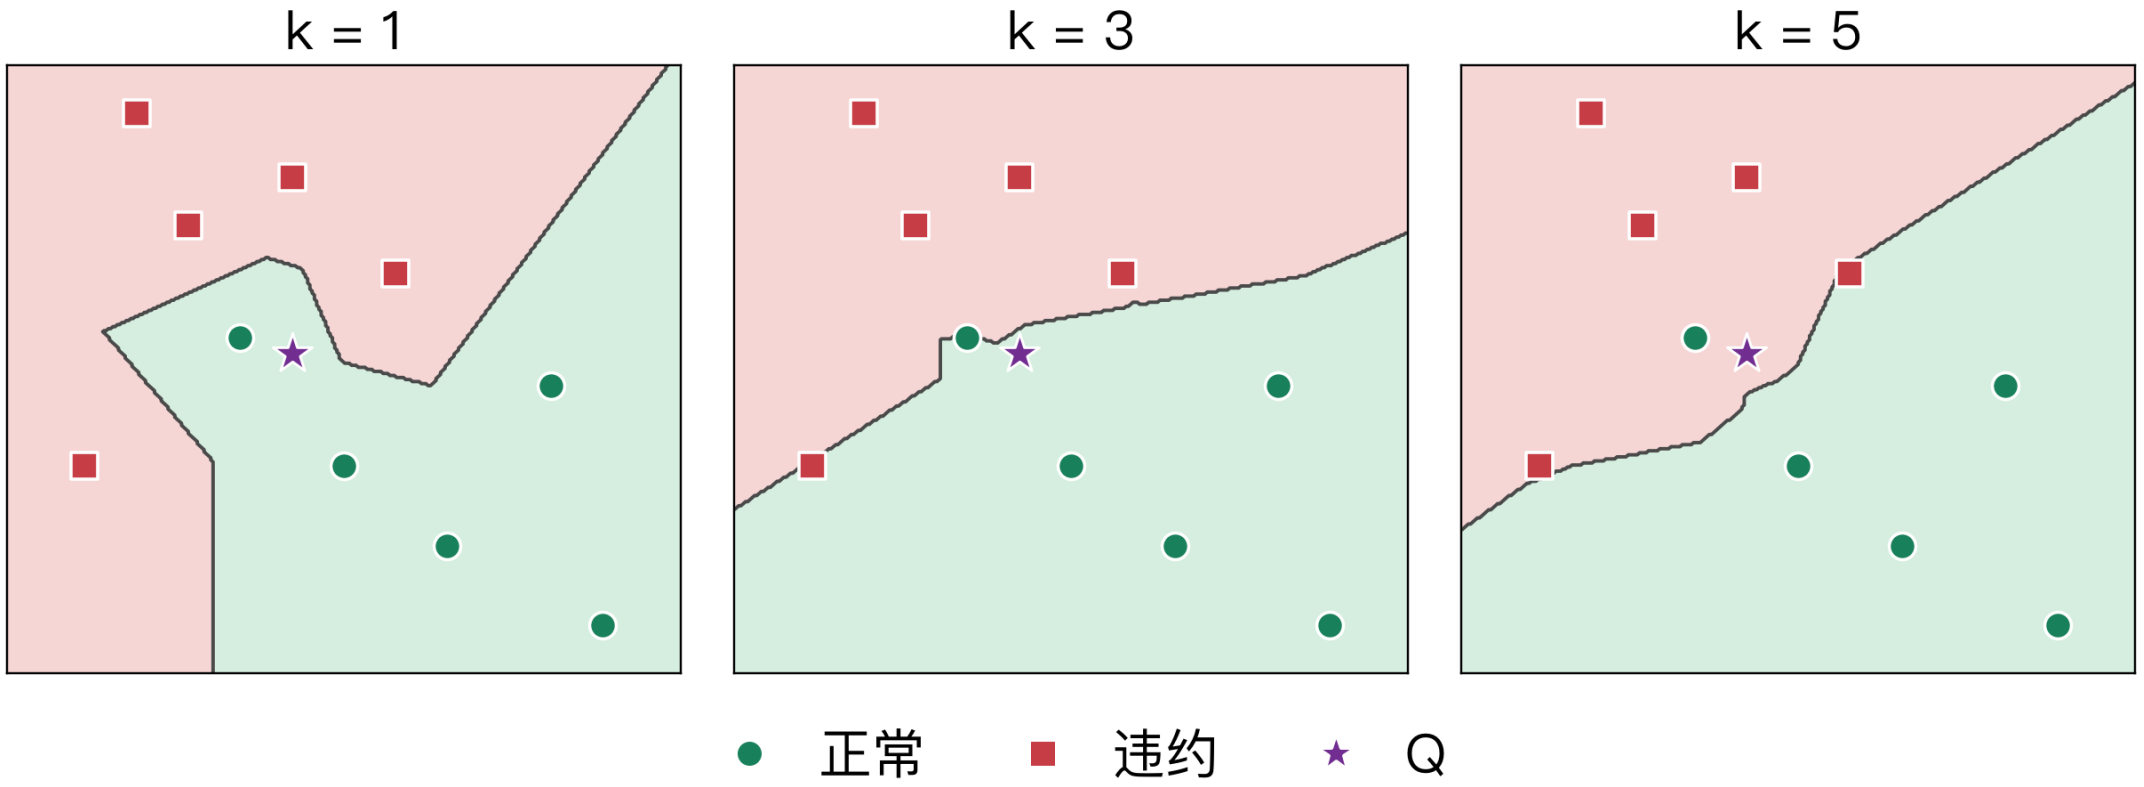


- 两个特征是月收入和负债收入比。
- 缩放后，两个邻居发生变化；预测从正常变为违约。
- 距离受特征尺度影响，通常需要先缩放。

案例：10 位历史借款人，教学构造数据。

k 值影响分类边界

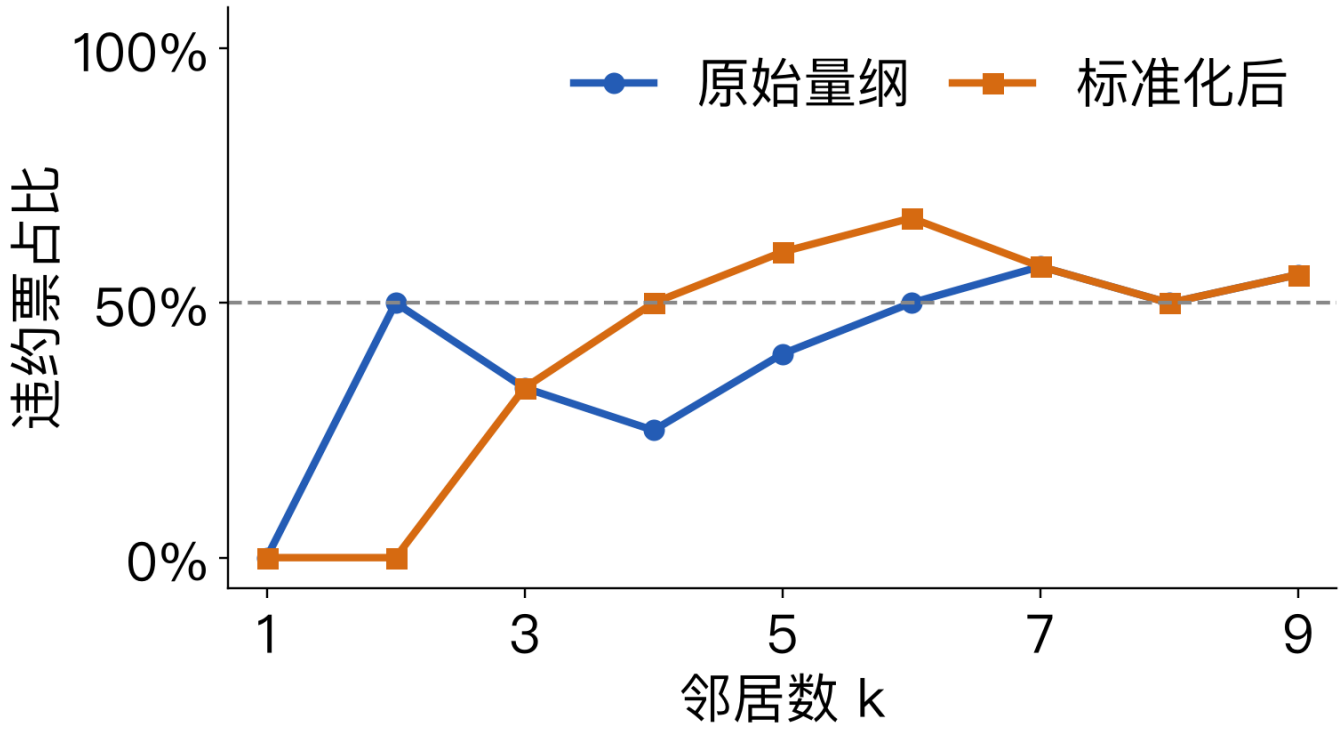
本例中，k 较小时边界更曲折；k 较大时边界较平滑。



k 太小易受噪声影响；k 太大可能忽略局部差异。用交叉验证选 k。

同一客户，预测可能随 k 改变

纵轴：邻居中违约者的比例。超过 50% 预测违约。

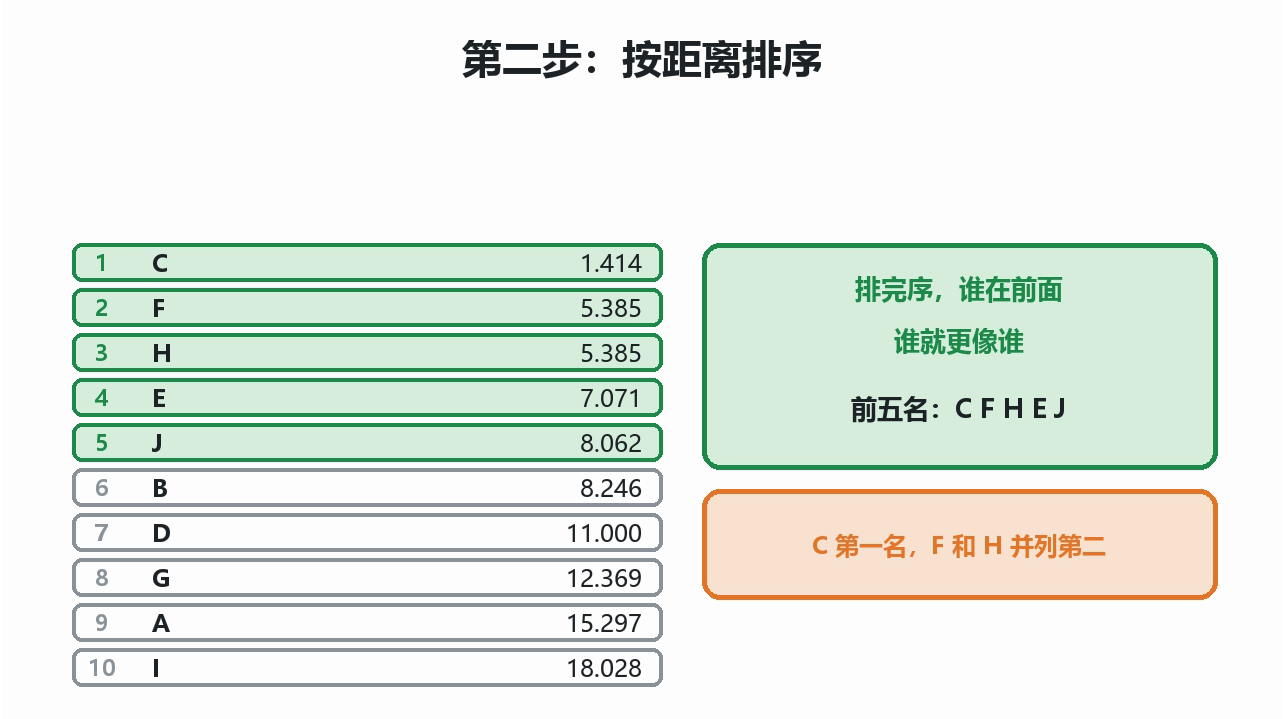


- k = 5：原始数据预测正常，缩放后预测违约。
- 本例在 k = 7、8、9 时，两条曲线重合。
- k 和特征尺度都可能改变结果。

蓝线：原始数据；橙线：缩放后。教学构造数据。

视频：kNN 算法步骤

2 分 48 秒；用同一组贷款数据演示五步流程。



播放视频

五步流程

算距离 → 排序 → 取 k 个邻居 → 统计类别 → 多数投票。

视频重点：标准化前后，k=5 的邻居和判决发生变化。

播放：视频文件位于“视频”子文件夹。

视频来源：本地课件配套视频。

3.朴素贝叶斯

从总体信息出发，再结合客户信息更新判断

贷款示例：A = 最终违约；B = 近期曾逾期

假设 100 人中：20 人违约，40 人曾逾期，其中 12 人两者皆是。

先验概率 总体 100 人中，20 人违约 → 20%

条件概率 违约的 20 人中，12 人曾逾期 → 60%

后验概率 曾逾期的 40 人中，12 人违约 → 30%

分类：比较各类别的后验概率，选择较大者（等误判成本）。

条件概率公式：

$$P(A|B)=\frac{P(AB)}{P(B)}$$

B 的概率大于零

3.朴素贝叶斯

贝叶斯公式：用已知信息更新概率

延续上页：A = 最终违约；B = 近期曾逾期

$$P(A|B) = P(B|A) \times P(A) \div P(B)$$

违约概率：60% × 20% ÷ 40% = 30%

60% 以违约客户为分母；30% 以近期逾期客户为分母。

全概率：把“近期逾期”的人数按是否违约分组

$$P(B) = \Sigma P(B|A_i) \times P(A_i)$$

本例：60% × 20% + 35% × 80% = 40%

各类别互斥且覆盖全部情况；P(B) 大于零。

3.朴素贝叶斯

朴素贝叶斯：在类别内简化特征关系

训练时估计类别比例和各特征在类别内的分布。

预测贷款违约时，可使用“近期逾期”和“收入不稳定”。

朴素假设	给定类别后，假设各特征联合条件独立。
注意	这是模型假设；特征在总体中仍可能相关。
应用	用于文本分类、风险识别等；效果需用数据验证。

样本 x：一组特征；类别 c：如“违约”或“未违约”。

3.朴素贝叶斯

分类决策：比较同一客户的后验概率

$$P(c|x) = P(x|c) \times P(c) \div P(x)$$

x 是客户特征，c 是类别；P(x) 大于零。

沿用第 20 页案例：客户近期曾逾期

违约	12 / 40 = 30%
未违约	28 / 40 = 70%

类别互斥且覆盖全部情况、误判成本相同时：选后验概率最大者。

本例预测“未违约”；这不代表该客户一定不会违约。

3.朴素贝叶斯

朴素假设：把多个条件概率相乘

给定类别 c 后，假设各特征联合条件独立。

$$P(x|c) = P(x_1|c) \times P(x_2|c) \times \ldots \times P(x_n|c)$$

类别分数 = 类别先验概率 × 各特征条件概率之积

客户近期逾期且收入不稳定；后者条件概率另设为 50% / 20%。

违约分数 20% × 60% × 50% = 0.060

未违约分数 80% × 35% × 20% = 0.056

同一客户比较分数；分数除以各类别分数之和，得到模型后验概率。

3.朴素贝叶斯

- 案例：西瓜数据集-训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

3.朴素贝叶斯

西瓜案例：从训练集估计概率

17 个已知标签的西瓜：好瓜 8 个，坏瓜 9 个

待判属性	好瓜中	坏瓜中
色泽：青绿	3 / 8	3 / 9
根蒂：蜷缩	5 / 8	3 / 9
敲声：浊响	6 / 8	4 / 9
纹理：清晰	7 / 8	2 / 9
脐部：凹陷	5 / 8	2 / 9
触感：硬滑	6 / 8	6 / 9

例：8 个好瓜中有 3 个青绿，所以 P(青绿 | 好瓜) = 3 / 8。

3.朴素贝叶斯

西瓜案例：计算并比较两类得分

给定类别后，假定六项属性之间条件独立。

待分类示例：青绿 • 蜷缩 • 浊响 • 清晰 • 凹陷 • 硬滑

分类得分 = 类别先验 × 六项条件概率

好瓜：8/17 × 3/8 × 5/8 × 6/8 × 7/8 × 5/8 × 6/8 ≈ 0.0339

坏瓜：9/17 × 3/9 × 3/9 × 4/9 × 2/9 × 2/9 × 6/9 ≈ 0.000861

好瓜得分较高 → 预测为好瓜。得分是未归一化的结果。

示例与训练集第 1 条相同，仅演示计算，不用于评估测试效果。

3.朴素贝叶斯

零频问题：一次没见过，不代表不可能

未平滑时，某类中的条件概率为 0，会影响整类得分。

① 数一数：8 个好瓜中，没有出现“敲声 = 清脆”。

② 算概率：P(清脆 | 好瓜) = 0 / 8 = 0

③ 看影响：好瓜得分乘以 0 后为 0，其他线索无法改变它。

如果坏瓜得分大于 0，模型就会预测为坏瓜。

应对：可以使用平滑方法，缓解训练数据中未见取值的问题。

3.朴素贝叶斯

朴素贝叶斯：优点与使用限制

适合作为分类任务的起点；最终效果要用独立数据验证。

优点

计算快，实现简单。

可以处理多分类任务。

适合建立分类基线；
部分实现支持增量训练。

使用限制

类别内特征可能相关，
独立假设不一定成立。

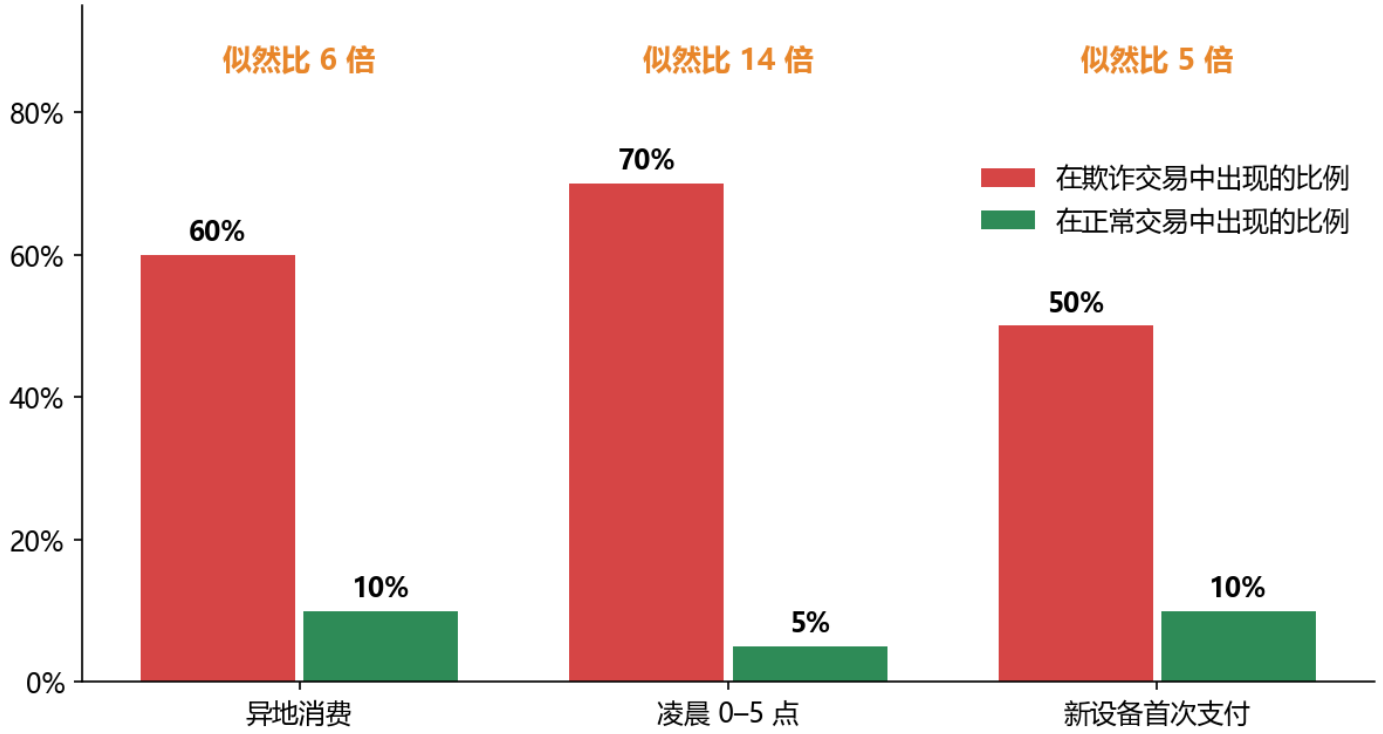
未平滑时可能出现零频；
连续特征需选择合适模型。

输出概率未必准确，
需检验分类效果与校准。

一条证据有多强

看它在两类里差得多不多，而不是它本身出现得多不多。

图 4 似然：每条证据在两类交易里各有多常见



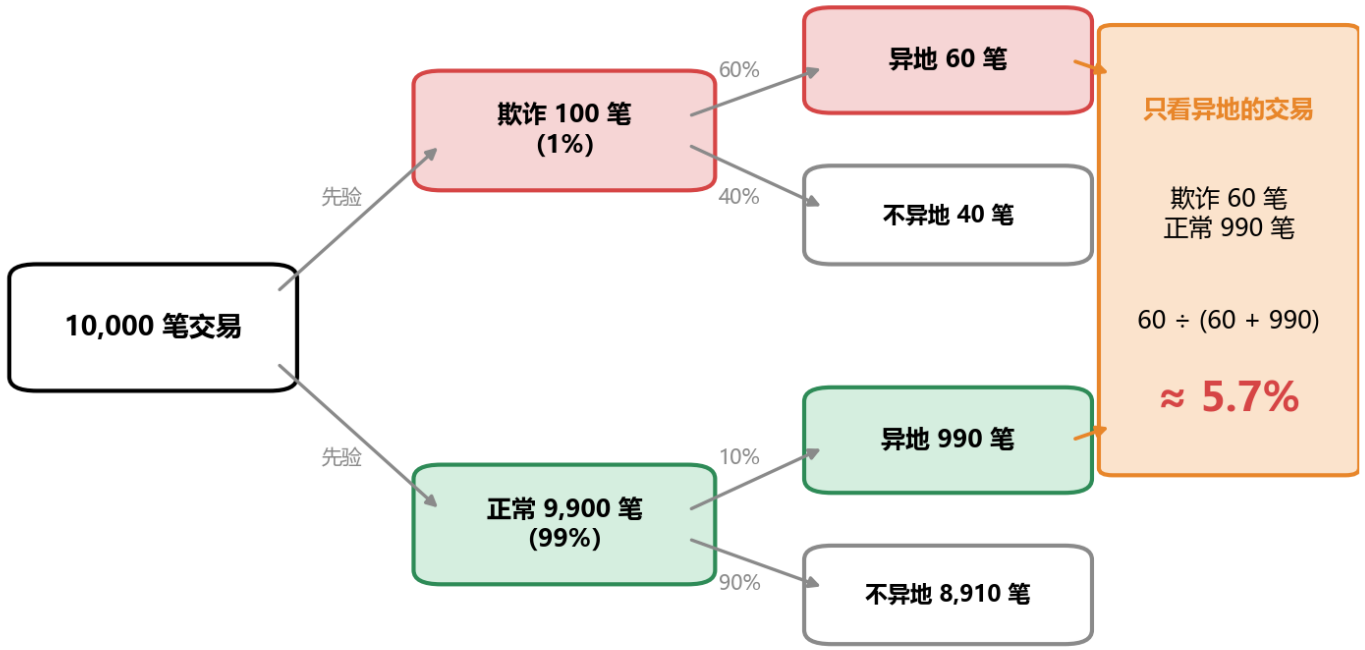
- 似然比 = 欺诈交易中出现比例 ÷ 正常交易中出现比例。
- “凌晨”的似然比约 14 倍，是最强的一条；异地约 6 倍，新设备约 5 倍。
- 单一“异地”信号只能把欺诈概率从 1% 推到 5.7%，先验很关键。

案例：10,000 笔信用卡交易，100 笔欺诈（教学构造数据）。

数人头就能算贝叶斯

把概率换成一万笔交易里有多少笔，公式就变成数数题。

图 5 用「频数树」看贝叶斯公式：异地交易里，正常交易的数量是欺诈的 16 倍以上



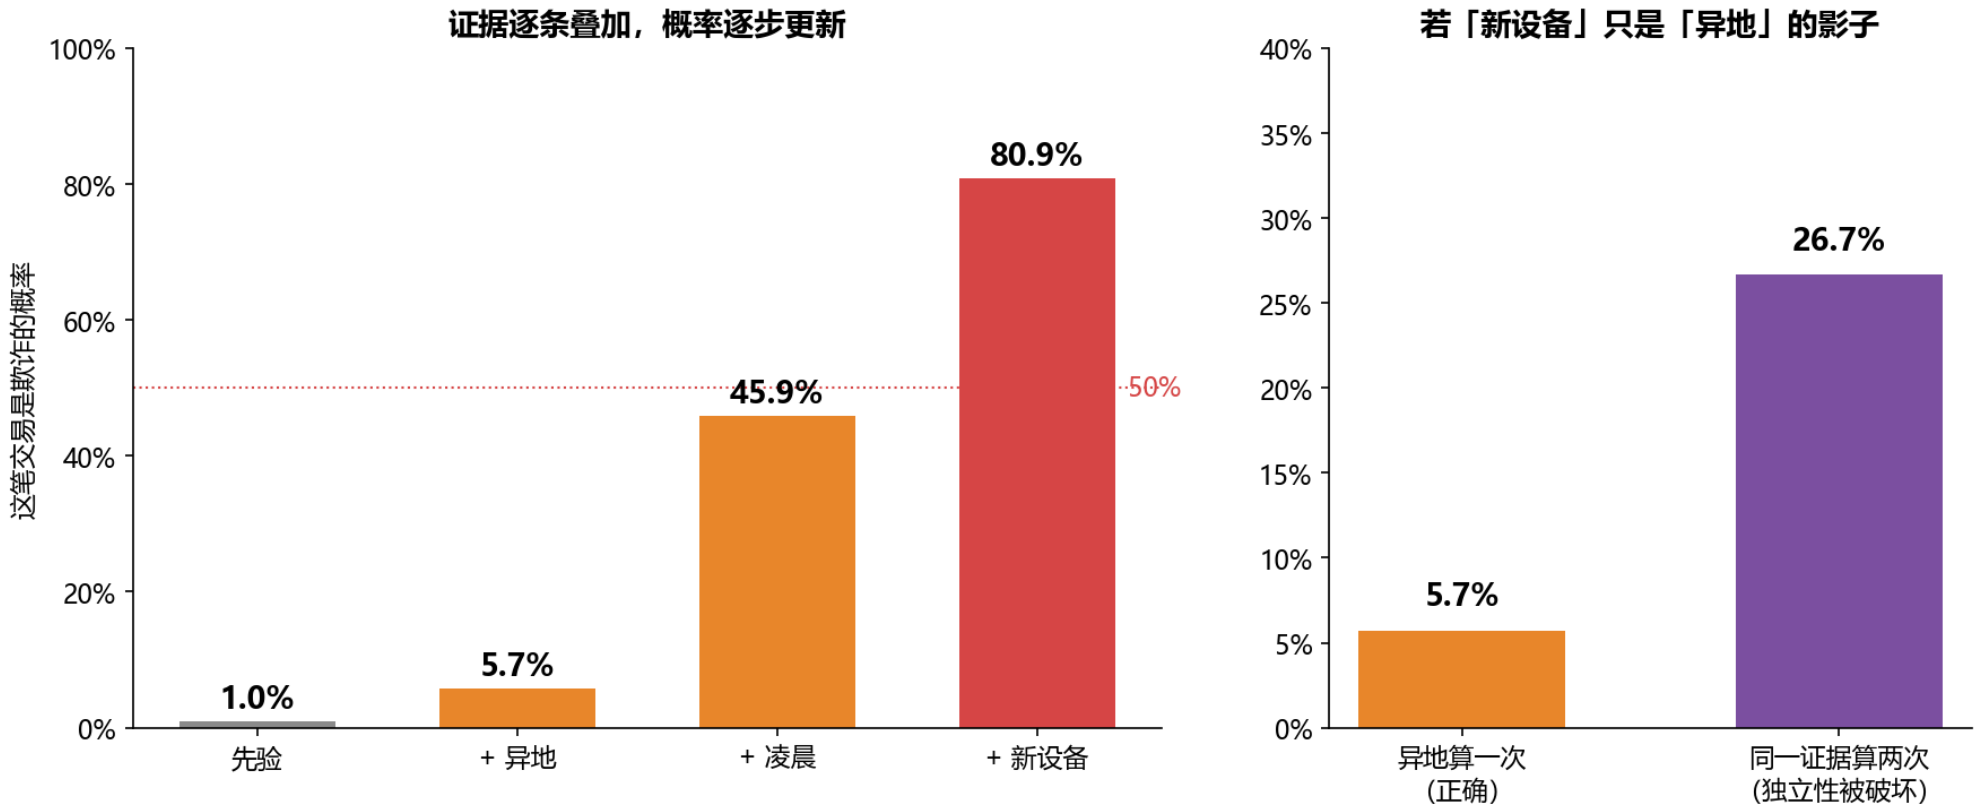
- 异地交易共 1,050 笔，其中欺诈 60 笔。
- 60 ÷ 1,050 ≈ 5.7%，与贝叶斯公式结果一致。
- 先验是第一层分叉，似然是第二层分叉，后验是把同一条件下的两类放在一起比。

频数树适合先建立直觉，再回到公式。

三条证据叠加：1% → 80.9%

每加一条证据，就把上一步的后验当作新的先验。

图 6　左：三条证据把 1% 推到约 81%；右：相关证据被重复计算，概率被放大

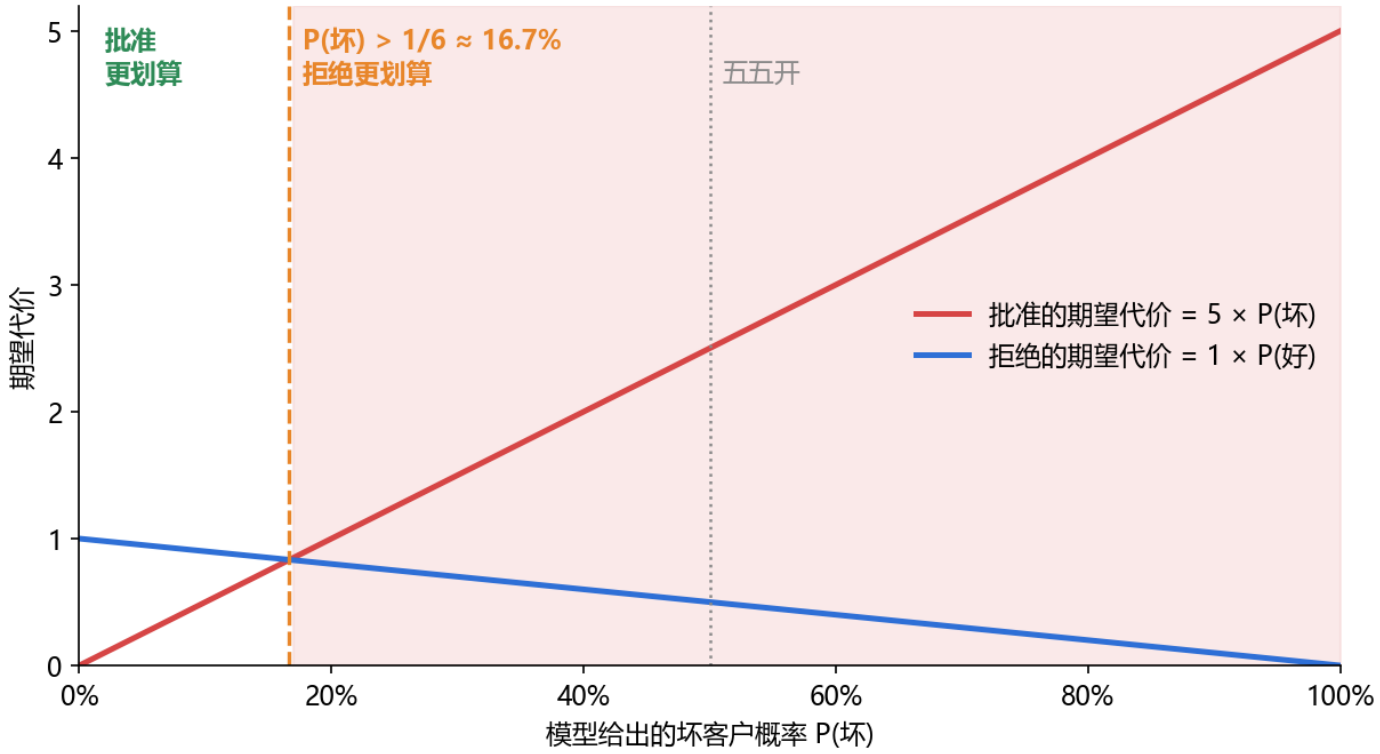


右图：当“新设备”只是“异地”的影子，独立性假设被破坏，概率被重复放大。

误判代价决定阈值

坏客户判好客户的代价是 5，好客户判坏客户的代价是 1。

图 7 误判代价决定阈值：坏判好代价 5，好判坏代价 1



- 当 5 × P(坏) > 1 × P(好)，即 P(坏) > 16.7% 时，拒绝更便宜。
- 模型只负责给出概率，阈值由业务代价决定。
- 错放一个坏人的代价越大，拒贷线越往左移。

来源：UCI Statlog German Credit；代价矩阵见 german.doc。

视频：朴素贝叶斯算法

3 分 16 秒；三条证据如何叠加。



播放视频

视频主线

先验 × 似然 → 后验；三条证据：异地、凌晨、新设备。

视频重点：独立性假设何时失效，概率为何被重复放大。

播放：视频文件位于“视频”子文件夹。

视频来源：本地课件配套视频。

4.决策树

决策树：通过连续提问做分类

从带标签的训练数据中学习划分规则，形成树状模型。

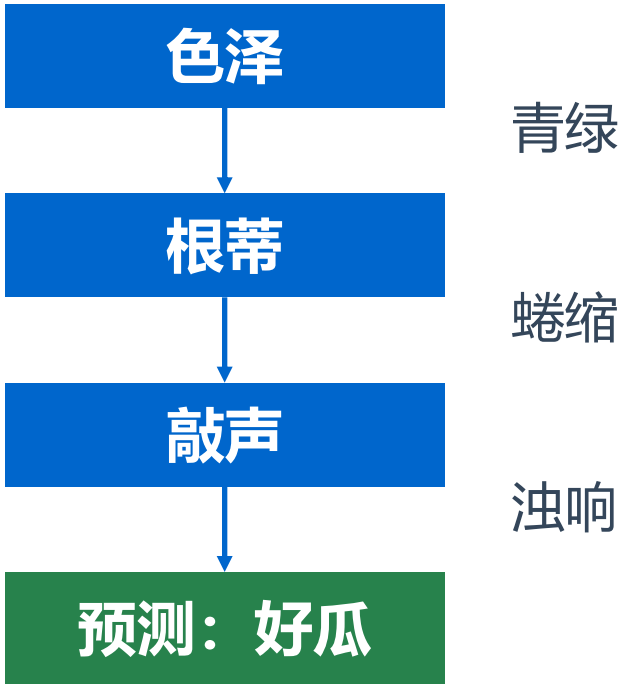
① 根节点：从第一个问题开始。

② 分支：按特征取值选择路径。

③ 叶节点：给出最终预测类别。

每次划分都让样本按特征进入不同分支。

西瓜示例：沿一条路径判断



4.决策树

西瓜案例：沿树的分支做判断

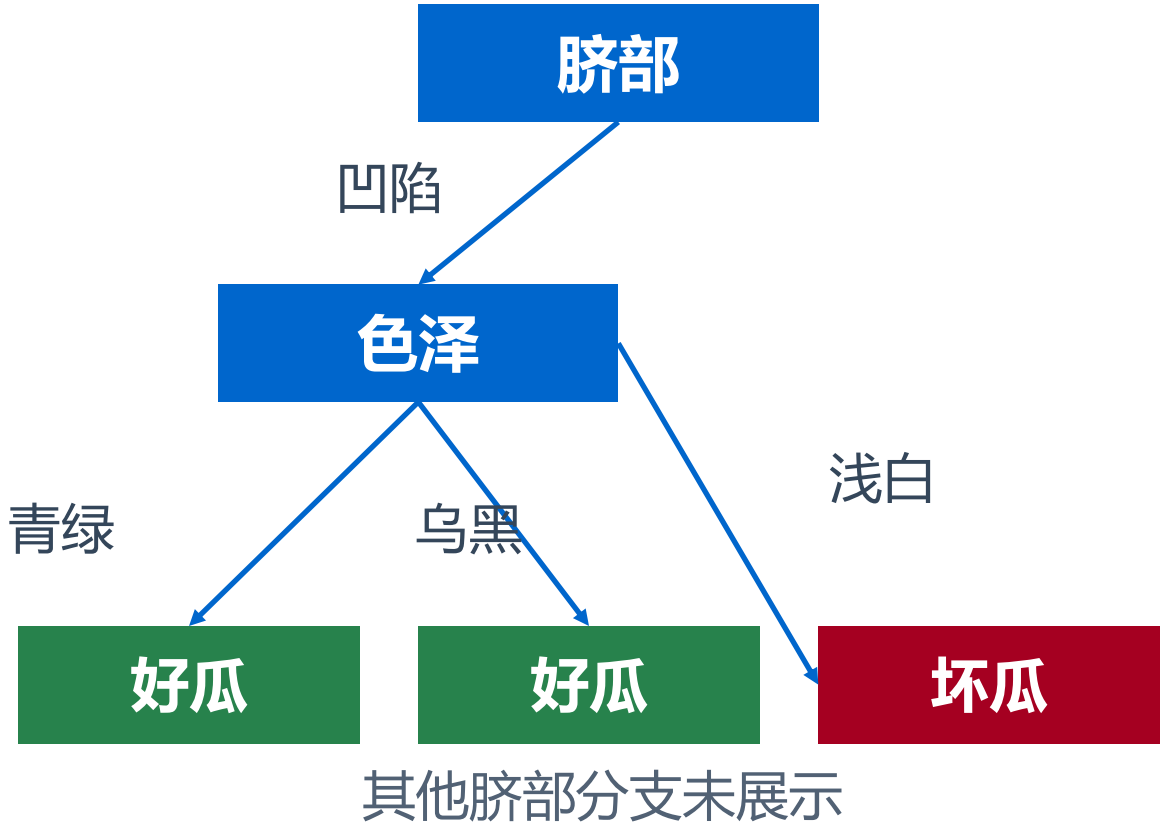
以下是另一棵示意树，展示其中一部分分支。

① 看脐部：凹陷 → 继续看色泽。

② 看色泽：青绿 → 到达好瓜叶节点。

③ 输出：模型预测这只瓜是好瓜。

预测来自这棵树的规则，不保证一定正确。



4.决策树

决策树怎样从数据中学到规则?

分类树使用带类别标签的训练数据，逐步划分样本。

1 比较候选划分 → **2 选择当前最优** → **3 继续划分**

例如比较色泽、根蒂等特征，观察划分效果。

按选定指标评估：信息增益越大，或基尼不纯度降低越多，划分越好。

常见方法采用贪心策略：每一步选当前较好的划分，不保证整棵树全局最优。

决策树 | 何时划分，何时停止?

输入：带类别的训练样本和候选特征

先看当前节点中的训练样本

满足停止条件 → 成为叶节点

样本同类：标记该类别
其他停止情况：标记多数类

否则 → 选择较好的划分

按特征划分样本；
对每个子节点重复上述过程。

可按算法设置停止阈值；多数类平票时按约定处理。

ID3｜按信息增益选择特征

经典 ID3：每次选择信息增益最大的离散特征。

1	**算信息增益**	比较当前节点的候选特征。
2	**选择最佳特征**	选择信息增益最大的特征。
3	**按特征值分组**	每个取值形成一个分支；移除已用特征。
4	**重复或停止**	对非空子集重复；同类或无特征时停止。

停止时：同类标该类；无有效划分取多数类。空分支取父节点多数类。

ID3算法

- **信息熵**是一个衡量样本集合纯度最常用的指标

$$Ent(D) = -\sum_{k=1}^{|Y|} p_k \log_2 p_k$$

$p_k(k = 1, \ldots, |Y|)$样本集中第k类的比例

- 假定离散属性a有V个可能的取值,则会产生V个分支。
- 第v个分支节点D中所有属性有特定取值的样本D^v
- 计算出信息熵，并考虑D^v占所有数据集的比例，可以得到信息增益

$$Gain(D, a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$$

ID3算法

- 信息增益越大，则意味着使用相应属性进行划分所得的信息纯度提升越大。
- 因此我们可以利用信息增益来进行决策树进行划分时候的属性选择

$$a^* = \arg\max_{a \in A} Gain(D, a)$$

ID3算法—案例

西瓜数据集-训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

ID3算法—案例

案例：按色泽计算信息增益

训练集共 10 个瓜：好瓜 5 个，坏瓜 5 个。

色泽	数量	好瓜	坏瓜	组内信息熵
青绿	4	2	2	1
乌黑	4	3	1	0.8113
浅白	2	0	2	0

原始信息熵：H(D) = 1　　乌黑组：$-(3/4)\log_2(3/4) - (1/4)\log_2(1/4) \approx 0.8113$

划分后加权信息熵：$4/10 \times 1 + 4/10 \times 0.8113 + 2/10 \times 0 \approx 0.7245$

信息增益：1 − 0.7245 = 0.2755

还需比较其他属性的信息增益，才能选择划分属性。

ID3算法

基础 ID3 的四个局限

信息增益是有效的划分指标，但使用时要注意它的局限。

01 取值多的属性可能占优势

信息增益倾向选择取值较多的属性，例如每人不同的编号。

02 容易过拟合

基础 ID3 通常不含剪枝；树长得过深，可能记住训练数据。

03 连续特征需要处理

基础 ID3 使用离散属性；连续数值通常需要先转换。

04 缺失值需要处理

基础 ID3 未直接规定缺失值的处理方法。

C4.5算法

C4.5：在 ID3 基础上改进

仍然逐步划分数据，但调整了划分指标和数据处理方式。

① 用信息增益率选择划分属性

增益率 = 信息增益 ÷ 固有值 IV

$$IV = -\Sigma\,(\text{各分支样本占比} \times \log_2 \text{各分支样本占比})$$

IV 衡量划分后样本分布；IV = 0 时无法直接计算增益率。

② 先生成树，再进行后剪枝

删除部分分支，可以降低过拟合风险。

③ 处理连续特征和缺失值

连续特征可按阈值划分；缺失值可按规则处理。

C4.5算法｜色泽的增益率

训练集 10 个样本：青绿 4、乌黑 4、浅白 2

固有值 IV $= -2 \times (4/10)\log_2(4/10) - (2/10)\log_2(2/10)$
≈ 1.5219

增益率 $= 0.2755 \div 1.5219 \approx 0.181$

先筛选信息增益高于平均值的属性；
再从候选属性中选择增益率最高者。

C4.5算法 | 为什么剪枝

反复划分可让训练样本更纯，
但过深的树可能把偶然特征当成规律。

预剪枝
生成过程中，决定是否继续划分

后剪枝
先生成树，再替换部分子树

目的：减少不必要的复杂度，降低过拟合风险。

预剪枝 | 在划分前判断

候选划分 → 比较验证集准确率 → 决定是否生长

① 节点样本数低于阈值：停止

② 没有可用特征：停止

③ 验证准确率未提高：本例停止

验证集用于选树；其准确率本身不能证明泛化能力。

预剪枝｜先建立验证基线

训练集：10 个样本
好瓜 5 ・ 坏瓜 5

根节点平票：本例预先约定
平票时标为“好瓜”

7 个验证样本全部预测为好瓜

预测正确：{4, 5, 8}　　错误：{9, 11, 12, 13}

3 / 7 = 42.9%

预剪枝｜先划分脐部，再检验节点②



划分后正确 {4,5,8,11,12}：5/7 = 71.4% > 42.9%

② 再按色泽分：青绿/乌黑→好，浅白→坏；
验证 5/7 → 4/7（57.1%），拒绝划分。

*③ 训练样本 2 好 2 坏，沿用平票标好瓜的约定。

预剪枝｜节点③与节点④

节点③：尝试按根蒂划分

验证准确率 5/7 → 5/7（71.4%）
本例要求严格提高，因此不划分。

节点④：训练样本 {10,16} 均为坏瓜

类别已纯，无需再划分。

得到的预剪枝树：②好瓜、③好瓜、④坏瓜。

后剪枝｜先生成完整树

训练树按信息增益生长；随后从下向上比较子树与叶节点。

① 脐部 = 凹陷 → ② 色泽
青绿 → 好瓜；乌黑 → 好瓜
浅白 → 坏瓜

① 脐部 = 平坦 → ④ 坏瓜
稍凹 → ③ 根蒂
蜷缩 → 坏；硬挺 → 好

③ 根蒂 = 稍蜷 → ⑤ 色泽：青绿→好；浅白→坏；乌黑→⑥纹理
⑥ 纹理：模糊→好，稍糊→好，清晰→坏

完整树的验证准确率：3/7 = 42.9%

空分支预测沿用原图；原资料未说明回退规则。

后剪枝｜逐个比较子树

⑥ 训练 {7,15}：一好一坏，类别平票

预先约定类别平票标好瓜；替换⑥后
验证 3/7 → 4/7（57.1%），执行剪枝。

⑤ 替换后仍为 4/7（57.1%）：准确率平票，
本例只在严格提高时剪枝，因此保留子树。

② 替换为好瓜后：4/7 → 5/7（71.4%），剪枝。

比较结果仅针对这 7 个验证样本，不是泛化能力证明。

CART算法

每个非叶节点选择一个问题，把样本分成两组。

当前样本集 D

是 → 子集 D左

否 → 子集 D右

$$\mathbf{Gini(D) = 1 - \Sigma_k\, p_k^2}$$

$$\text{Gini划分} = |D左|/|D| \times \text{Gini}(D左) + |D右|/|D| \times \text{Gini}(D右)$$

p_k 是类别 k 的样本比例；比较候选划分，越小越纯。

CART算法

案例：按“触感”二分，共 10 个样本

硬滑：6 个 | 3 好 3 坏

$1 - (3/6)^2 - (3/6)^2 = 0.5$

软粘：4 个 | 2 好 2 坏

$1 - (2/4)^2 - (2/4)^2 = 0.5$

加权基尼 = 6/10 × 0.5 + 4/10 × 0.5 = 0.5

这是该候选划分的分数；还需与其他候选划分比较。

CART算法

本例：选择一个类别，其余类别归另一侧。

例：色泽 ∈ {青绿、乌黑、浅白}

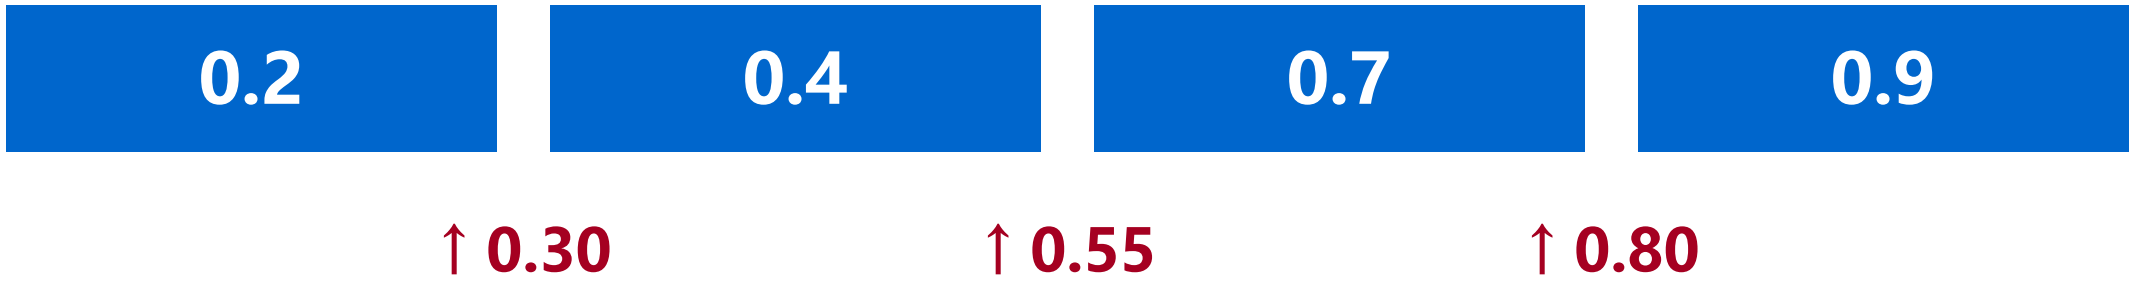
青绿	vs	乌黑、浅白
乌黑	vs	青绿、浅白
浅白	vs	青绿、乌黑

比较上述候选的加权基尼；一般实现也可考虑类别子集对其余类别。

CART算法

先排序不同取值，在相邻值的中点尝试阈值。

例：密度取值 0.2、0.4、0.7、0.9（教学假设）



以阈值 t 为界：x ≤ t 进入左侧，x > t 进入右侧。

m 个不同取值对应 m−1 个中点；比较划分分数。

CART算法

回归树：选择使两个子节点平方误差总和最小的划分。

$$\text{SSE划分} = \Sigma_{左}(y_i - \bar{y}_{左})^2 + \Sigma_{右}(y_i - \bar{y}_{右})^2$$

等价于比较按样本占比加权的总体方差。

叶节点预测：该节点内训练样本目标值的均值。

后剪枝

用叶节点替换子树，比较验证误差；
或用代价复杂度选择子树。

4.决策树

优点

- 路径直观，便于解释
- 一般无需特征标准化
- 可衡量特征重要性

局限与实现差异

- 容易过拟合；可剪枝
- 对训练数据扰动敏感
- 缺失值处理与增量学习能力取决于具体实现

候选分裂：比较四个问题

14 位借款人：逐项比较分组结果与加权基尼。

		加权基尼
负债收入比	低：7人/违约1人　高：7人/违约5人	0.327
历史逾期	无：9人/违约2人　有：5人/违约4人	0.337
工作满3年	否：8人/违约5人　是：6人/违约1人	0.387
有房	否：8人/违约4人　是：6人/违约2人	0.476

深蓝表示违约；负债收入比的加权基尼最小。

限制树的生长深度

不限深度：训练准确率 100%；深度 2：85.7%。

不限深度 · 6叶

负债高否→逾期否 5人/违约0

负债高否→逾期是→工作满3年否 1人/违约1

负债高否→逾期是→工作满3年是 1人/违约0

负债高是→工作满3年否 4人/违约4

负债高是→工作满3年是→逾期否 2人/违约0

负债高是→工作满3年是→逾期是 1人/违约1

max_depth=2 · 4叶

负债高否→逾期否 5人/违约0

负债高否→逾期是 2人/违约1

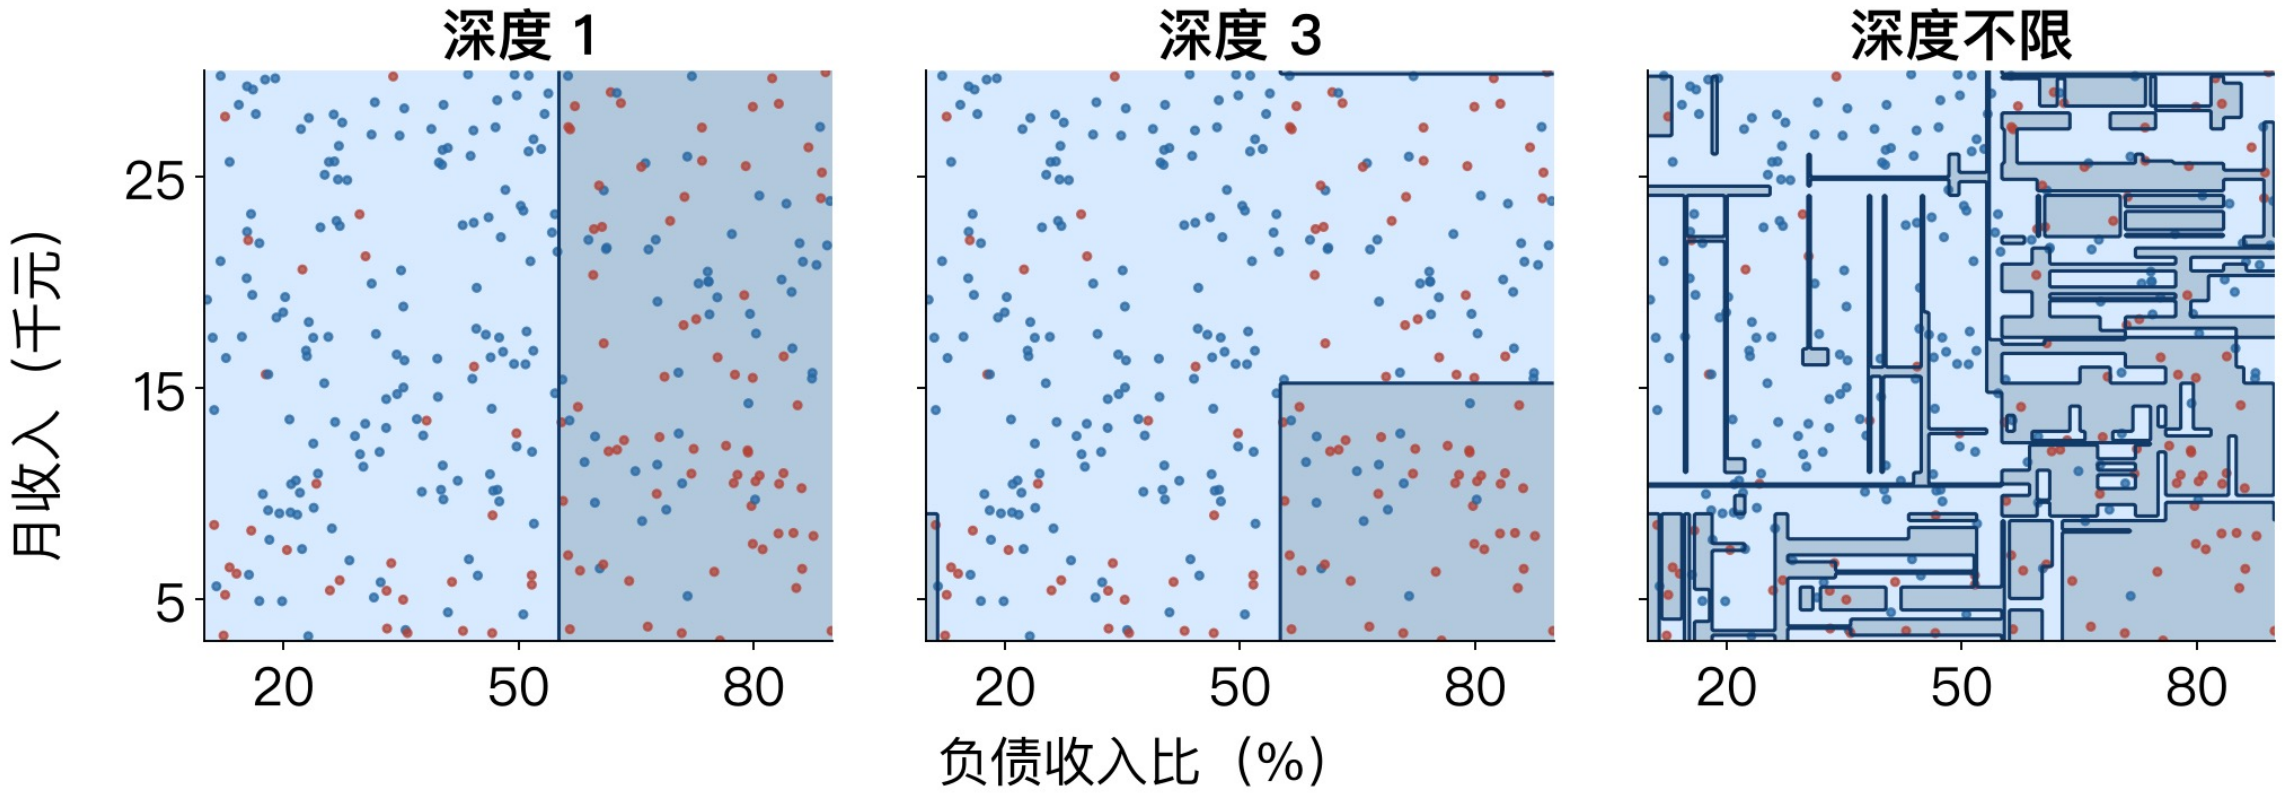
负债高是→工作满3年否 4人/违约4

负债高是→工作满3年是 3人/违约1

每行是一条从根到叶的路径；右侧叶节点至少 2 人。

决策树如何切分平面

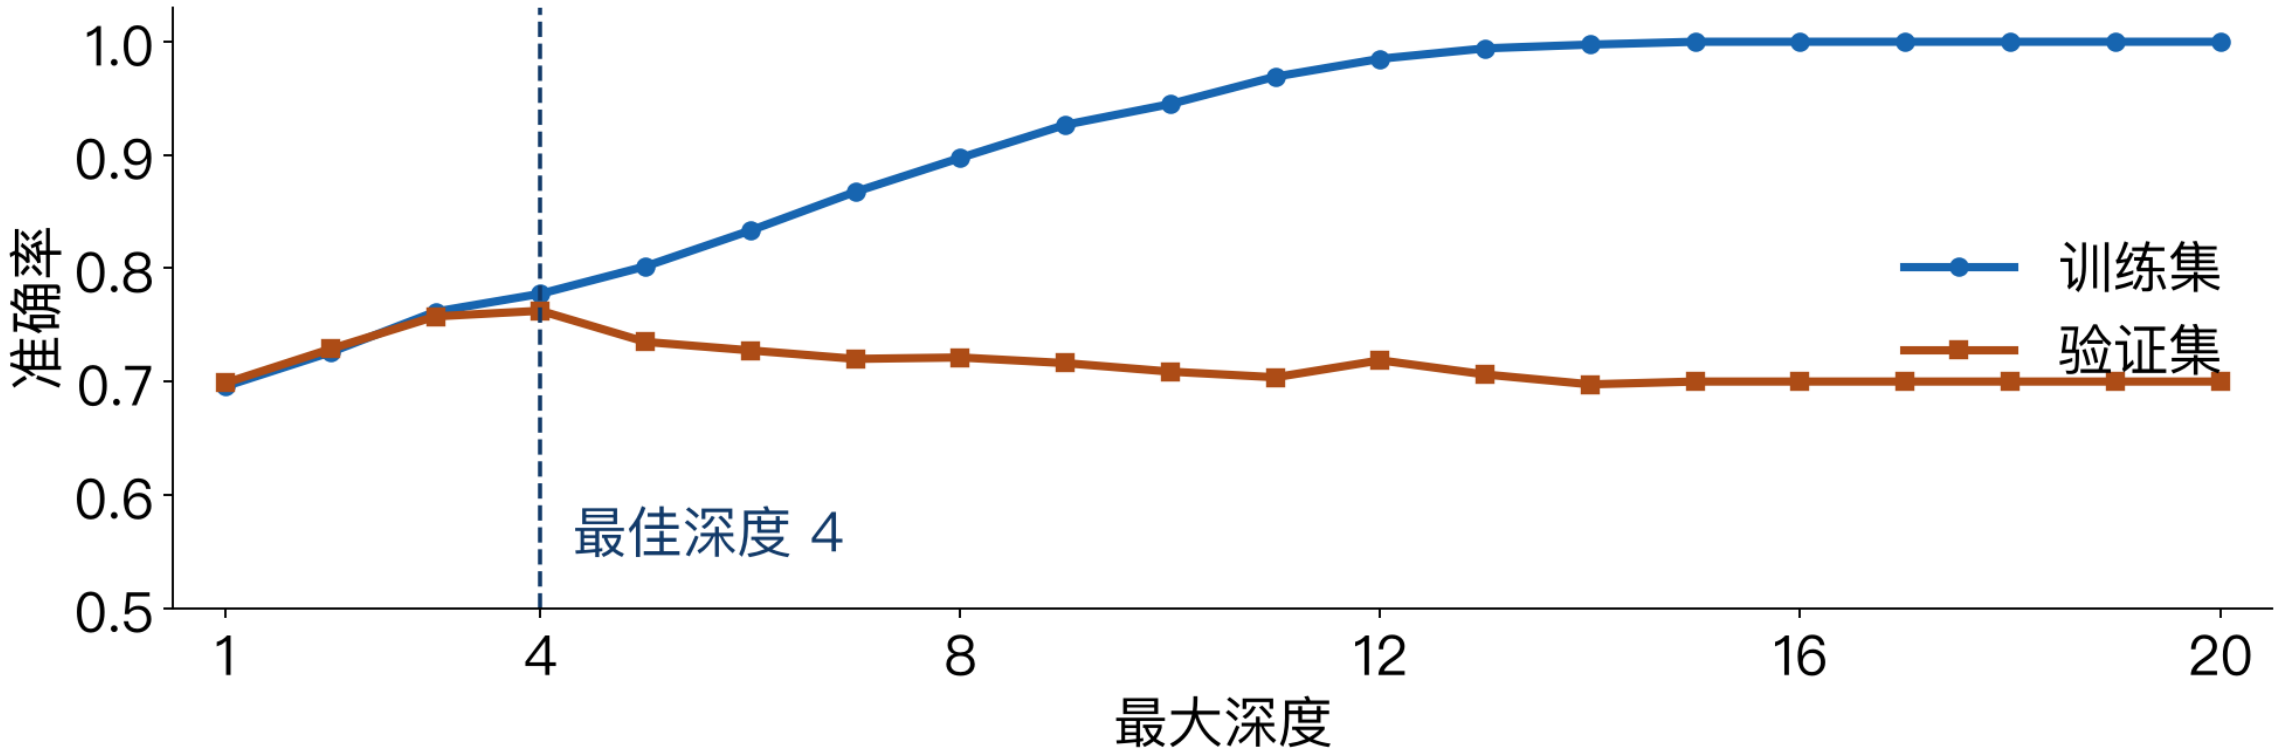
每次分裂产生水平或垂直边界；深度增加会细分区域。



模拟数据；蓝点正常、红点违约；底色表示预测类别。

训练集与验证集：选择树深度

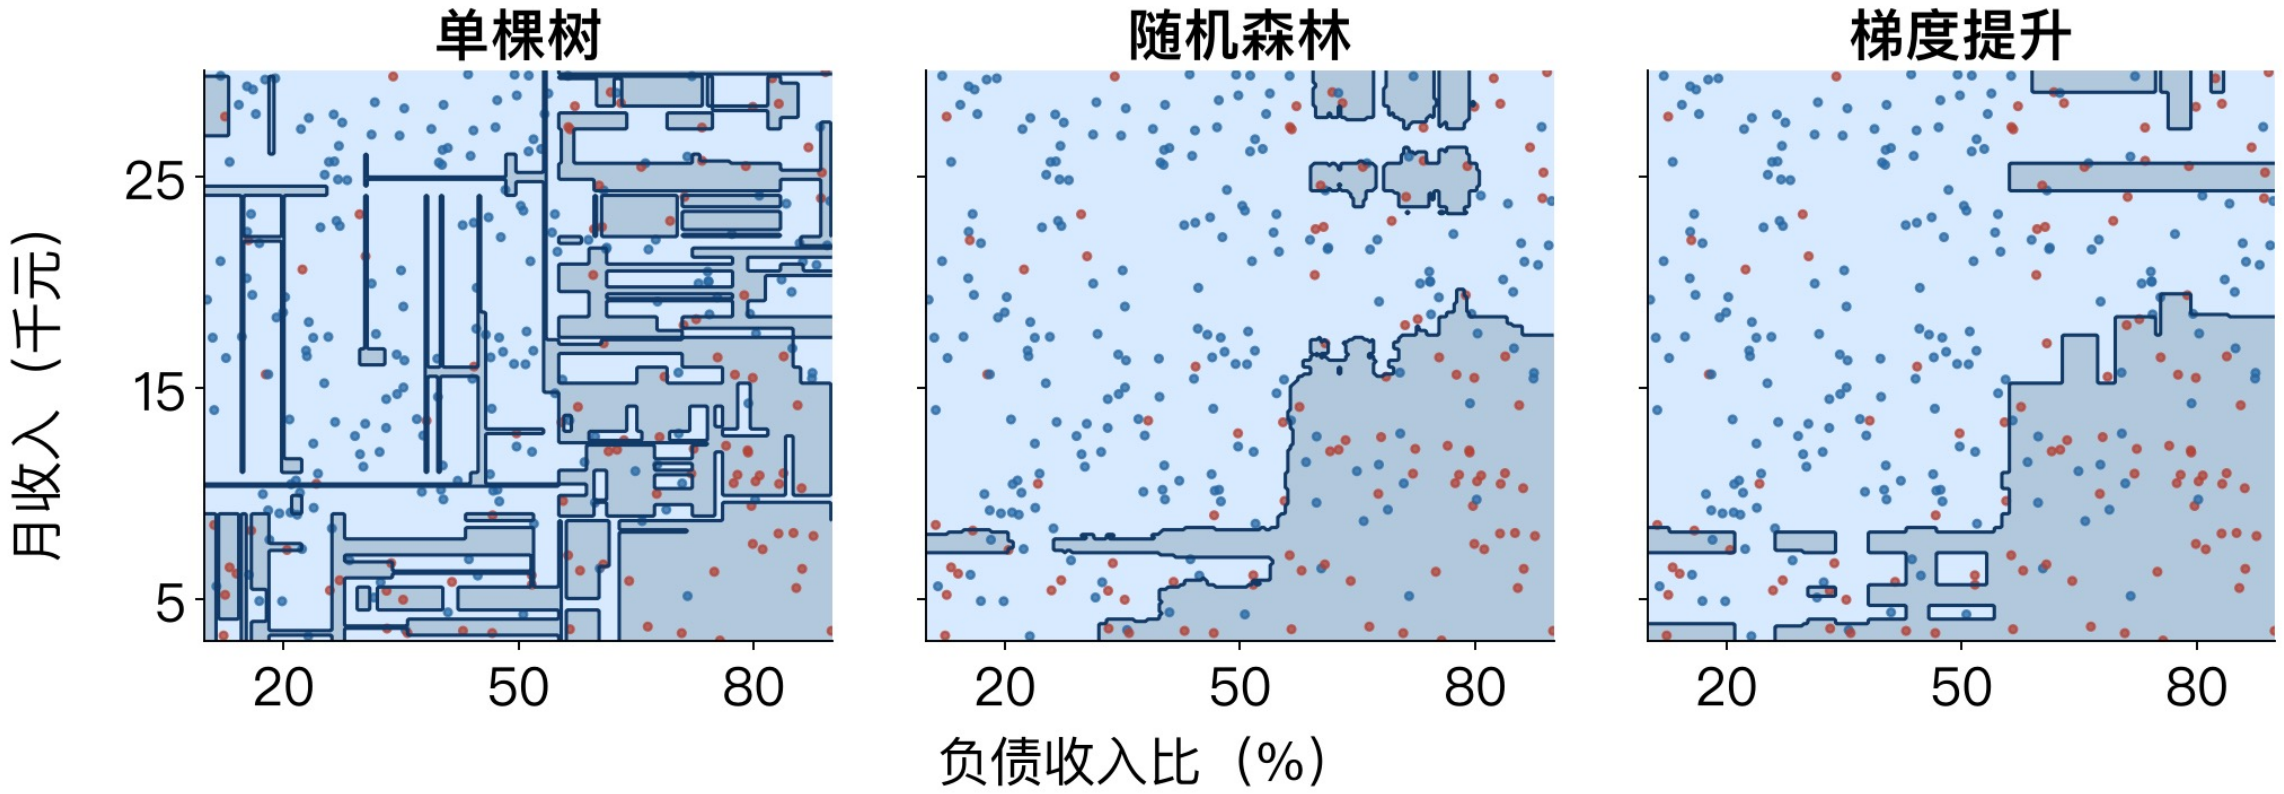
训练集 60%，验证集 40%；模拟数据含 6 个噪声特征。



验证集用于选深度；此例未留独立测试集。

从单棵树到集成模型

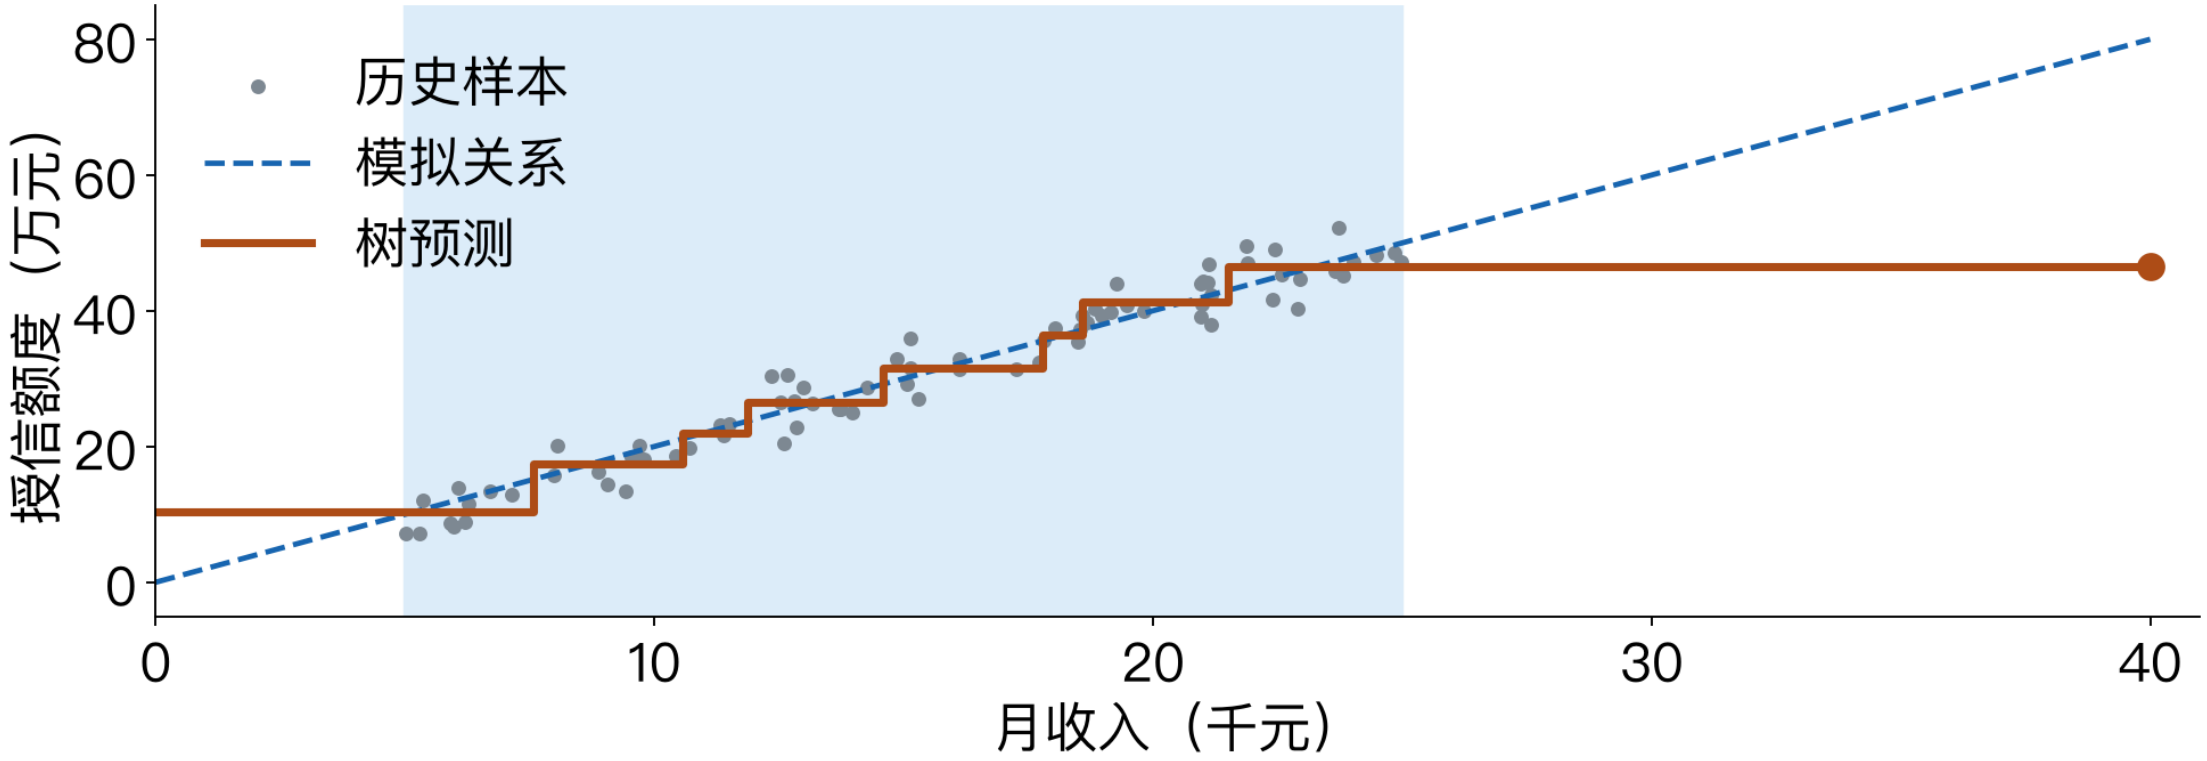
随机森林汇集多棵树投票；梯度提升逐步添加树。



模拟数据；森林 300 棵树，梯度提升 80 棵浅树。

回归树与训练区间外的预测

横轴收入（千元），纵轴额度（万元）；模拟数值关系 y≈2x。



收入 4 万元即横轴 40；树预测额度约 47 万元。

三模型对照

三种模型没有绝对优劣，关键是问题、数据形态和解释要求。

kNN

按距离找相近样本

保留训练样本；选 k

风险：量纲、维数

缩放：常需考虑

朴素贝叶斯

用条件概率比较类别

估计概率或分布参数

风险：条件独立假设

缩放：通常不必

决策树

按特征逐层划分

得到一组判断规则

风险：过拟合、不稳定

缩放：通常不必

一句话：kNN 靠相似，朴素贝叶斯靠概率，决策树靠规则。

课堂讨论

任选两题，用本讲的概念回答。

01 身份证号为何可能被 ID3 选中？C4.5 能完全避免吗？

02 风控选单棵树还是 XGBoost？如何比较效果与解释性？

03 kNN 缩放前后结果不同，如何用验证集比较？

结合案例说明判断依据和适用条件。