人工神经网络

从识别规律到设计应用

大数据金融

生活中常见的识别任务

手机相册

自动把相似的照片归在一起

邮箱系统

提示一封邮件可能是垃圾邮件

视频平台

根据观看记录推荐内容

共同特点

它们都要从大量信息里找规律

规则由谁来写?

人工编写规则

人先定条件，计算机照着判断。

从数据中学习

人准备任务和样本，算法自己从样本里找判断的依据。

以垃圾邮件为例：只看某个关键词，很容易误判；模型能把邮件里的多种信息放在一起判断。

什么是人工神经网络

由许多相互连接的计算单元组成的模型

1. 接收输入，逐层处理，输出预测结果
2. 设计灵感来自生物神经网络
3. 但它不是对人脑的完整复制

输入、处理与输出

以识别邮件为例

输入		处理		输出
邮件正文 发件人信息	→	综合各类信息 对照样本找规律	→	是垃圾邮件的可能性 或一个分类结果

网络中的"神经元"

每个神经元只做两步：加权求和，再压缩成 0 到 1 之间的数

第 ① 步　加权求和

$$z = w_1x_1 + w_2x_2 + w_3x_3 + b$$

w_1、w_2、w_3：权重，表示各项输入有多重要。正数推高结果，负数拉低结果

b：偏置，不随输入变化的基础值

z：加权求和的结果

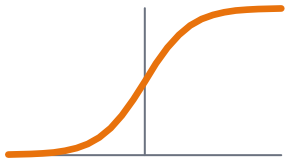
第 ② 步　压缩到 0 与 1 之间

$$a = \sigma(z) = 1 / (1 + e^{-z})$$

σ：压缩函数（sigmoid）

e：自然常数，约等于 2.718

a：神经元的输出，交给下一层



σ 把任意数压进 0 到 1 之间

z 很大，a 接近 1

z 很小，a 接近 0

许多神经元逐层连接，就是神经网络：单个很简单，靠整体配合完成复杂判断。

为什么需要多层处理

以图片识别为例



最终输出类别，例如“猫”或“狗”。不同模型学到的内容不尽相同，也未必能用人类的语言解释。

模型怎样学习

以有已知答案的样本为例

1. 给模型一批样本和对应的答案
2. 模型先预测，再和答案比较
3. 根据差距调整网络中的参数
4. 重复这一过程，训练误差逐步变小

这种训练方式叫监督学习

怎样衡量“差多少”

$$L = (\hat{y} - y)^2$$

$\hat{y}$：读作“y 帽”，模型的预测

y：历史答案

L：损失，衡量预测与答案的差距

^{2}：平方：差得越多，损失涨得越快

预测 0.9，答案 1：$(0.9 - 1)^2 = 0.01$

预测 0.1，答案 1：$(0.1 - 1)^2 = 0.81$

训练，就是想办法让损失变小

对所有样本取平均，就是“训练集平均损失”

参数调整与反向传播

参数是模型内部的数值，靠训练调整，不靠人工设定

1. 反向传播：算出每个参数的变化会怎样影响误差
2. 训练方法据此调整参数，再进入下一轮学习

每一轮，每个参数这样更新一小步

$$w \leftarrow w - \eta \cdot \partial L / \partial w$$

新参数 = 旧参数 − 步长 × 损失的变化方向

像下山：看清脚下哪边更低，朝那边走一小步，再看一次。公式只需认识，不要求推导。

符号说明

w：要调整的参数

←：更新为：用右边算出的值，作为 w 的新值

η：步长（学习率），每次调整多大

L：损失，见上一页

$\partial L / \partial w$：w 增大一点，损失 L 会怎样变；反向传播就是在算它

−：朝损失变小的方向走

学会样本，还要面对新情况

训练

用已有样本调整模型参数

测试

用训练时没用过的样本检验模型

训练样本上表现好，不代表遇到新情况也表现好。

模型若过度贴合训练样本的细节，面对新数据时表现会变差，这叫过拟合。

回顾：前面几种方法怎样找规律

关联规则

找出经常一起出现的项目

kNN

找出最相似的历史样本，参考邻居的类别

朴素贝叶斯

结合类别的常见程度和当前证据，比较哪一类可能性更大

决策树

从数据中建立一串判断条件，沿分支得出结果

它们解决的问题不同，都要先准备数据，再检验结果是否有用

神经网络有哪些不同

比较角度	此前所学方法	神经网络
数据怎么表示	通常先由人挑选、整理特征，再交给算法	同样要准备输入；多层网络还能逐层学出有用的表示
结果怎么形成	找相似样本、比较类别可能性，或沿条件分支判断	信息逐层计算，训练调整连接参数，最后输出结果
怎样理解结果	相似样本、简单的决策路径通常比较直观	连接和参数很多，单次结果往往难以直接解释

这是便于理解的概括，不是严格的分界

什么时候考虑哪种方法

1 **先看任务**

是要发现商品的共现规律，还是预测一笔交易的类别？

2 **再看数据**

数据量、数据类型和质量，都会影响选择

3 **比较效果，兼顾使用条件**

用测试数据比较各方法；是否要求可解释，数据和算力够不够

复杂不等于更好，简单方法够用就是好选择

从输入和输出来理解应用

应用	输入	可能的输出
图片识别	图片	图片中的物体
语音识别	一段语音	对应的文字
文本处理	一段文字	文本类别，或生成的文字
交易风险提示	一笔交易的信息	是否需要进一步核查

任务不同，数据和目标也不同，一个应用的效果不能直接套到另一个应用上

生成式人工智能与神经网络

一些生成式人工智能以大型神经网络为基础

1. 根据输入生成文字、图片等内容
2. 生成的内容可能有错误或遗漏，重要信息仍需核实

神经网络既能做分类和预测，也能生成内容

金融领域的应用场景

交易风险提示

找出值得进一步核查的交易

客户服务

识别咨询的主题，帮助查找相关信息

信用风险分析

结合资料和历史结果，辅助评估风险

市场分析

找与价格变化相关的历史信息

效果取决于具体任务、数据质量和使用环境，不能保证预测准确

先明确要解决的问题

场景

一家银行每天收到大量信用卡申请，需要安排人手审核

教学目标

根据申请时已有的信息，预测这份申请能否通过现行审批流程

使用方式

模型只提供参考，最终由审核人员按规定和具体情况决定

先分清两种不同的问题

问题	要预测的结果	可用的历史答案
申请能否通过审批	过去审批是否通过	历史审批结果
客户未来是否违约	未来是否发生违约	后续还款记录

本案例选第一个问题。历史审批结果只反映过去的审批决定，不能当作客户今后是否违约的答案。

准备什么样的样本

一条教学样本可以包含：

1. 申请时已有的信息，如收入区间、已有负债
2. 对应的历史审批结果：通过或未通过
3. 足够多的历史样本，用于学习和检验

使用数据前，要先明确来源、使用权限和保护措施。示例字段只用于说明

从样本到模型

1. **检查样本**：有没有缺失的信息，记录有没有明显问题
2. **整理数据**：把可用的信息转成模型能处理的形式
3. **划分数据**：一部分样本用来训练，另一部分留着检验
4. **训练模型**：让模型从申请信息与历史审批结果的对应关系中学习
5. **检验结果**：看模型在没参与训练的申请上表现如何

模型输出什么

对一份新申请，模型会输出一个“通过审批”的预测分数

1. 分数高：通过的可能性较大
2. 分数低：通过的可能性较小
3. 分数可能出错，要看测试结果
   仅供参考，不替代审批规定和人工审核

算一算：同一个神经元，两份虚构申请

$z = 0.2\times$月收入 $- 0.05\times$负债比 $- 1\times$逾期次数 $+ 0.5$

分数 $= \sigma(z) = 1 / (1 + e^{-z})$

0.2、−0.05、−1 是三个权重 w，0.5 是偏置 b；z、σ、e 的含义同第 6 页

	申请甲	申请乙
月收入（千元）	12	6
负债收入比（%）	20	60
历史逾期（次）	0	1
z（加权求和）	1.9	−2.3
预测通过分数	**87%**	**9%**

权重为教学虚构；真实网络有大量权重，由训练得到。

预测错误会带来什么影响

模型判断	实际审批结果	需要关注的影响
预计通过	未通过	审核人员要重新核查
预计未通过	通过	合适的申请被耽误，或被额外审查

只看总体正确率不够，还要分别看两类错误及其后果。

如何检查模型是否可用

1. 在没参与训练的样本上检验表现
2. 分别看通过和未通过的预测情况，以及两类错误
3. 和简单做法比一比，看模型是否真有帮助
4. 留意不同群体是否受到不合理影响，并查明差异的原因
5. 上线后持续观察：人群和业务环境变了，表现可能随之改变

历史决定可能带来历史偏差

模型学到的是历史审批决定里的规律

1. 过去的决定若有偏差，模型可能把偏差延续下去
2. 有些信息容易获取，也未必适合用于审批

要检查数据和结果，并保留人工复核与纠错的渠道

应用设计的完整思路

明确问题	要预测什么？结果由谁使用？
准备数据	有哪些合法可用的信息？答案是什么？
训练与检验	模型在没见过的样本上表现如何？错误会带来什么后果？
投入使用	怎样让使用者看懂结果、复核决定，并持续跟踪效果？

神经网络的优势与局限

可能的优势

能从大量样本中学出较复杂的关系

能处理图片、语音、文字等数据

需要注意

结果取决于数据质量和训练方式

预测会出错，判断过程也难以解释

数据多、模型复杂，不一定更好

使用模型，别忘了背后的人

1. 涉及个人信息时，要关注数据的取得、使用和保护
2. 模型的判断会影响不同的人，要检查有没有不合理的差异
3. 对个人影响重大的决定，要有明确的责任人和复核方式
4. 上线后继续观察，发现问题及时调整

本课回顾

1. 神经网络用相互连接的计算单元，把输入变成输出
2. 监督学习：用预测与答案的差距（损失）调整参数
3. 评价模型，要看它在新数据上的表现，也要看错误的后果
4. 选方法看任务和实际效果，不盲目追求复杂
5. 设计应用，先想清问题和数据，再选模型、做检验、投入使用

理解一项人工智能应用

可以从四个问题入手：

1. 它要解决什么问题？
2. 它使用什么数据？
3. 如何知道它是否可靠？
4. 谁来使用结果并承担责任？

谢谢大家