大数据金融

人工神经网络

从识别规律、历史演进到金融场景设计

原理细节 · 发展脉络 · 行业应用 · 信用卡审批案例

生活中常见的识别任务

手机相册整理

自动识别人脸、宠物或票据，把相似的照片归到同一个相册

电子邮箱过滤

结合邮件文字、发件人和链接特征，提示一封邮件可能是垃圾邮件

视频平台推荐

根据观看时长、点赞和跳过记录，推测观众下一步可能感兴趣的内容

共同特点：海量归纳

这些功能面对的都是千变万化的真实数据，必须从大量样本中寻找可用规律

要点 日常软件里的“智能判断”，背后大多是在海量历史样本里自动寻找统计规律。

规则由谁来写

思路一 人工编写规则

人先总结条件，再让计算机机械执行

例如：标题含“中奖”或“限时返现”就拦截

局限：只要换个写法或拆字，规则就会失效

思路二 从数据中学习

人先明确任务并准备样本和答案

算法综合多种线索，自己总结出判断规律

优势：面对新写法，只需补充样本就能更新

以识别垃圾邮件为例：单靠某一个关键词很容易把正常通知误判成垃圾邮件，从数据中学习能同时权衡多种线索。

要点 机器学习把“人写条件”变成“人定目标并准备样本，由模型自己学出规律”。

本课的学习目标

01 看懂内部细节

搞清神经元、激活函数、隐藏层、归一化、损失与反向传播各起什么作用

02 理清历史脉络

明白神经网络为什么经历两次寒冬，又如何从感知机走到今天的大模型

03 辨析金融场景

看懂反欺诈、信用评估、文本处理与市场预测各自的业务痛点和适用边界

04 走通应用设计

借信用卡审批案例和课末互动网页，完成问题定义、验证检验与风险把关

课程定位：面向商科与通识背景，重点放在概念理解、业务判断与风险意识，不要求推导公式或编写代码。

要点 不背数学推导，重点看懂原理直觉、技术演进以及金融场景里的能力边界。

02

神经网络的细节与工作机制

什么是人工神经网络

结构 相互连接的计算单元

由许多简单计算单元分层排列，上一层的输出作为下一层的输入

仿生 受到人脑神经元启发

借鉴了“多个信号汇聚后再触发响应”的想法，但并非对生物人脑的完整复制

机制 靠调整连接强度来学习

真正储存知识的地方，是网络里成千上万条连接上的权重数值

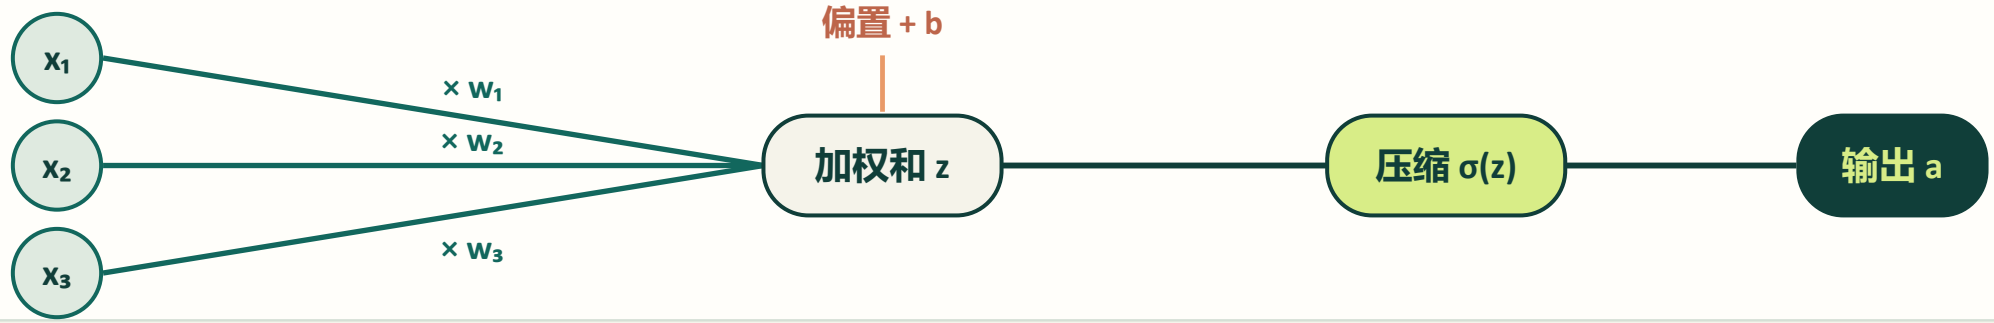
输入信息（数字向量） → **逐层加权与非线性变换** → **输出预测分数或类别**

以邮件过滤为例：输入邮件正文词频、发件人历史与链接信息，经过多层综合计算，输出“是垃圾邮件的可能性”。

要点 神经网络不是神秘黑魔法，它本质上是一组按层连接、可反复调参的数学计算步骤。

网络中的“神经元”

单个神经元的内部两步：先加权求和，再压缩输出



第 ① 步 加权求和

$$z = w_1x_1 + w_2x_2 + w_3x_3 + b$$

x_1, x_2, x_3：输入信号（收入、负债、逾期）
w_1, w_2, w_3：权重（正推高、负拉低结果）
b：偏置（基础门槛）；z：加权和

第 ② 步 压缩到 0 与 1 之间

$$a = \sigma(z) = 1 / (1 + e^{-z})$$

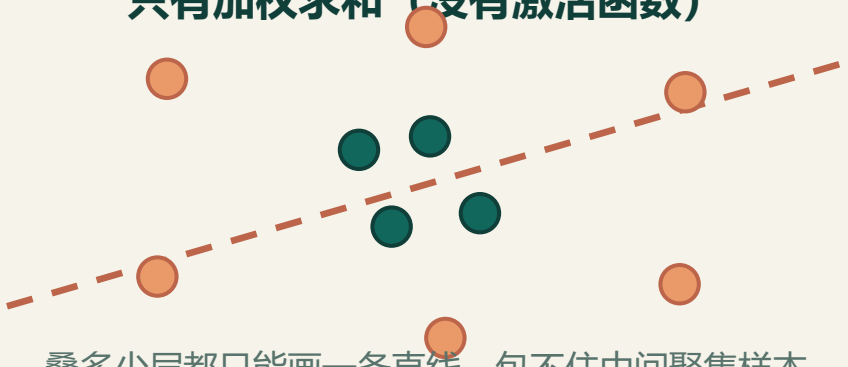
σ：Sigmoid 压缩函数，压进 0 到 1 之间
e：自然常数，约等于 2.718
z 越大 a 越近 1，越小越近 0，输出传给下层

要点 每个神经元只做两步：按重要程度打分求和，再用激活函数压缩输出。

为什么一定要有激活函数

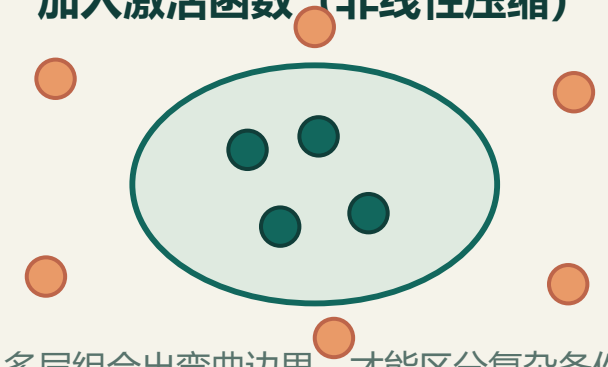
如果去掉压缩函数，多层叠加在数学上仍然退化成一条直线

只有加权求和（没有激活函数）



叠多少层都只能画一条直线，包不住中间聚集样本

加入激活函数（非线性压缩）



多层组合出弯曲边界，才能区分复杂条件

直觉一：不能只做乘法加法

两条直线相加减，得到的永远还是直线；哪怕叠十层，没有非线性就切不开弯曲边界

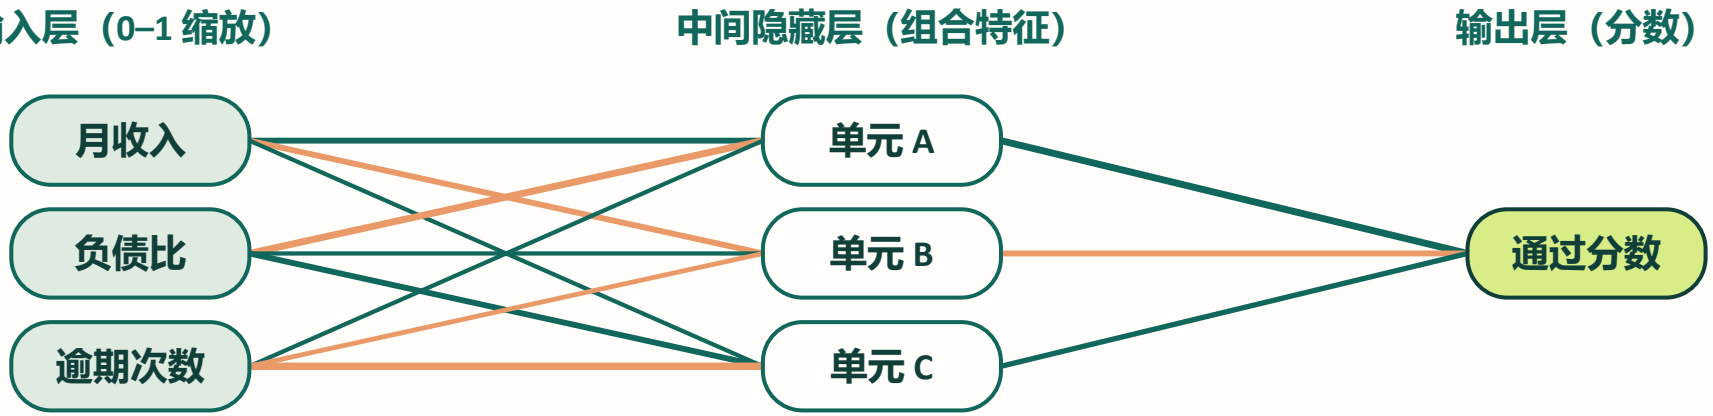
直觉二：金融条件常常拐弯

例如“高收入如果叠加高负债与多次逾期”依然高风险，这种交叉组合需要非线性边界

要点 激活函数把“死板的直线打分”变成“会拐弯的曲线组合”，这是多层网络有威力的原因。

从单个神经元到多层网络

3 → 3 → 1 三层网络示意（与课末信用卡审批互动页结构一致）



第一层先看简单信号

比如原始的月收入、负债比和逾期次数

中间层组合隐含概念

各单元自动把输入配对，学出“偿债压力”或“信用习惯”等中间特征

输出层综合给出判断

把中间层的几个抽象结论汇总，形成最终的预测分数

要点 中间隐藏层不靠人工起名字，而是在训练中自动替我们组合“中间特征”。

细节一：为什么输入要做归一化

对比情况	输入数值举例	可能带来的后果
不做归一化（原始尺度）	月收入 12000 元 ｜ 负债比 0.40 ｜ 逾期 1 次	收入数值高出几万倍，加权时容易淹没小尺度特征，参数步调也难统一
先做归一化（0 到 1 之间）	月收入 0.75 ｜ 负债比 0.50 ｜ 逾期 0.33	所有特征在同一把尺子上参与打分，权重直接反映贡献，训练更稳

回忆第 03 次课

kNN 算距离时如果月收入不标准化，2 万元的收入差会把负债率完全淹没；神经网络同理，输入前也要统一尺度

工程注意：只用训练集尺子

用来做缩放的最大最小值或均值，只能从训练样本里计算，不能偷看测试集数据

要点 归一化把不同单位的变量拉回同一把尺子，防止“数值大”的特征掩盖“重要”的特征。

模型怎样学习：监督学习与损失

1 给样本与答案 → 2 模型先作预测 → 3 计算预测误差 → 4 调参再来一轮

用“损失”衡量猜得离答案有多远

$$L = (\hat{y} - y)^2$$

$\hat{y}$（读作 y 帽）：模型给出的预测值 | y：样本里的已知答案

平方的作用：无论偏高还是偏低，差得越多，损失涨得越快

两个数字例子直观对比

已知答案 y = 1，预测 $\hat{y}$ = 0.9 → 损失 = $(0.9 - 1)^2$ = 0.01

已知答案 y = 1，预测 $\hat{y}$ = 0.1 → 损失 = $(0.1 - 1)^2$ = 0.81

把所有训练样本的损失求平均，就是“训练集平均损失”

训练的目标，就是反复调整参数，让这个平均损失逐步降下来

要点 利用“已有答案”对比误差并不断改错的学习方式，叫做监督学习。

细节二：参数调整与反向传播

正向计算 从左往右算出结果

输入信息经过一层层权重计算，在最右边得到预测分数，并与答案比对出误差

反向传播 从右往左追究责任

把误差沿连接线倒推回去，算出每一条连接上的权重该往哪个方向调、调多大幅度

每一轮训练，每个参数沿着误差变小的方向更新一小步

$$w \leftarrow w - \eta \cdot \partial L / \partial w$$

w：要调整的权重 | ←：更新为右边新数值 | η（学习率）：每次迈多大步子

∂L/∂w：w 增大一点时损失 L 怎么变（坡度）；负号表示朝损失变小的方向走

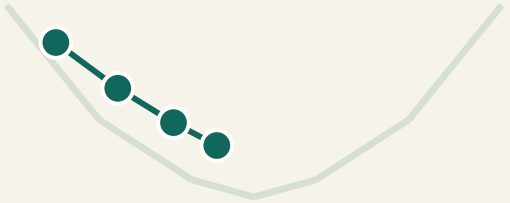
像下山找最低点：先摸清坡度再迈一小步，反复试探（本课只理解思路，不推导）

要点 反向传播不是魔法，它用微积分的链式思路帮成千上万个参数分摊“误差责任”。

细节三：学习率 η 的取舍

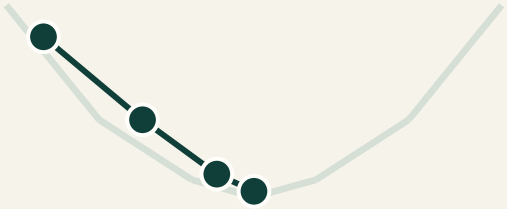
学习率 η 决定每一步迈多大：太小走不动，太大跨过头

η 太小：步子太碎



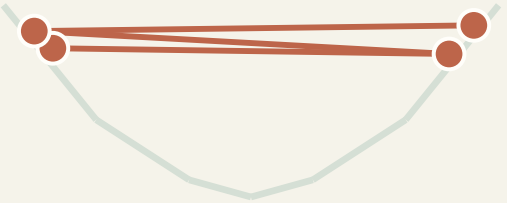
走了很久还在半山腰，训练慢

η 合适：步幅适中



稳步落到误差最低的谷底

η 太大：跨过头了



在谷底两侧来回弹跳甚至偏离

步子太小（η 过小）

方向没错但推进极慢，训练很多轮损失依然居高不下，耗费大量计算时间

步子太大（η 过大）

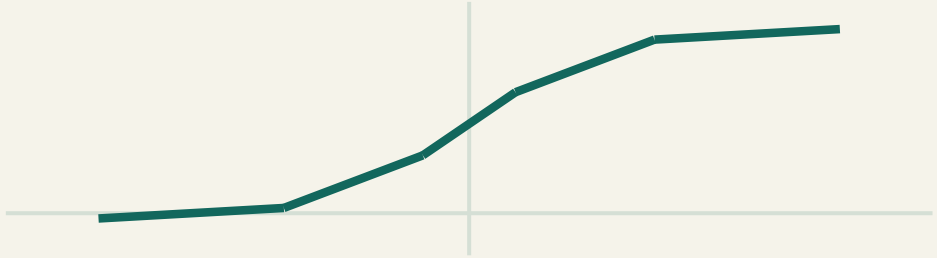
一步跨过谷底冲到对面山坡，误差不降反升，甚至在数值上发散溢出

要点 训练神经网络不仅看算法，学习率等“超参数”设得合不合适直接决定能不能学会。

细节四：为什么后来常用 ReLU

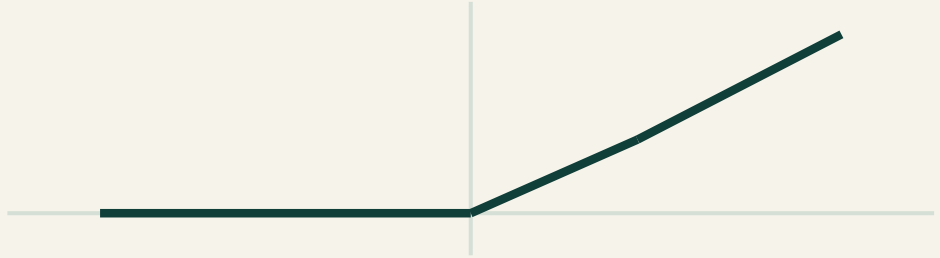
早期小网络常用 Sigmoid 输出概率；深层网络内部常改用 ReLU

Sigmoid：压缩到 0 到 1



z 很大或很小时曲线变平，深层传递时变化变微弱

ReLU：max(0, z)



负数归零、正数原样直传，深层网络更易训练

Sigmoid 的深层瓶颈

输入很大或很小时曲线走平，反向传播经过几层后信号衰减到几乎为零，深层学不动

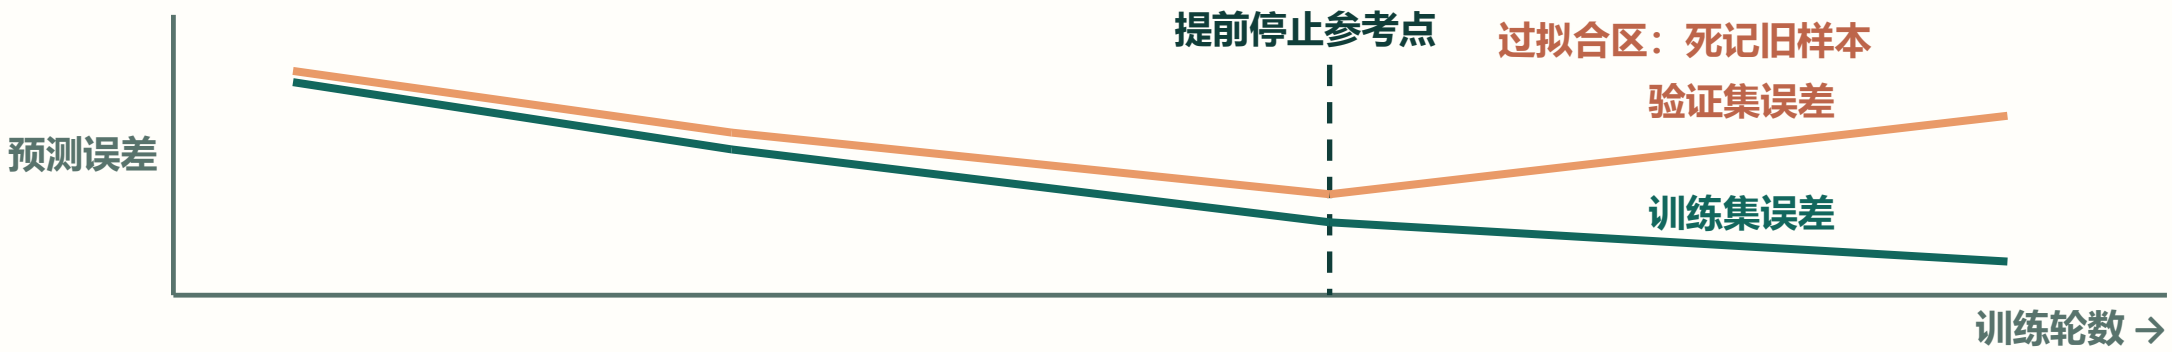
ReLU 的直观优势

公式取 0 和 z 较大值（负数归零、正数直传）
算得极快，信号也能顺畅传到浅层

要点 正是 ReLU 这类简单改动，帮神经网络打破了过去“层数一深就训不动”的僵局。

学会样本，还要面对新情况

训练集误差一直降，不代表对新样本一直变好（提前停止示意）



训练集（Training）

用来计算损失并调整参数，就像平时刷的练习题

验证集（Validation）

每轮结束后挑轮数与设置，误差回升就提前停止

测试集（Test）

模型定型后再考一次，反映面对新情况的独立表现

要点 死记训练样本细节会导致在新数据上变差，这叫过拟合；必须用未见过的数据检验。

回顾：与此前所学方法对比

比较角度	关联规则 / kNN / 贝叶斯 / 决策树	人工神经网络
特征怎么来	往往先由人挑选、整理有用特征，再交给算法处理	表格数据也需准备输入；面对图像、语音、文本还能逐层自动学出表示
怎样形成判断	找共现项目、找相似邻居、比较概率或沿决策树条件分支	输入信息经多层线性加权与非线性激活，通过反复调参形成预测输出
怎么解释原因	共现规律、相似案例或较浅的树路径，通常比较容易说清理由	内部有成千上万个连接权重，单次判断往往难以浓缩成一句话规则

概括提示：传统方法也从数据中学习，神经网络同样离不开人的问题定义与数据整理。

要点 神经网络擅长自动学表示与处理非结构化数据，但代价是可解释性下降。

什么时候考虑哪种方法

01 先看任务类型

找商品搭配用关联规则；结构化表格预测常先试树模型和简单分类器；图像语音长文本常用神经网络

02 再看数据规模

几百到几千条结构化客户表，传统方法往往又快又稳；神经网络通常需要更大量的数据喂养

03 考虑解释要求

金融拒贷常需向客户与监管说明理由，高合规要求场景不宜盲用黑箱

04 算力与试错成本

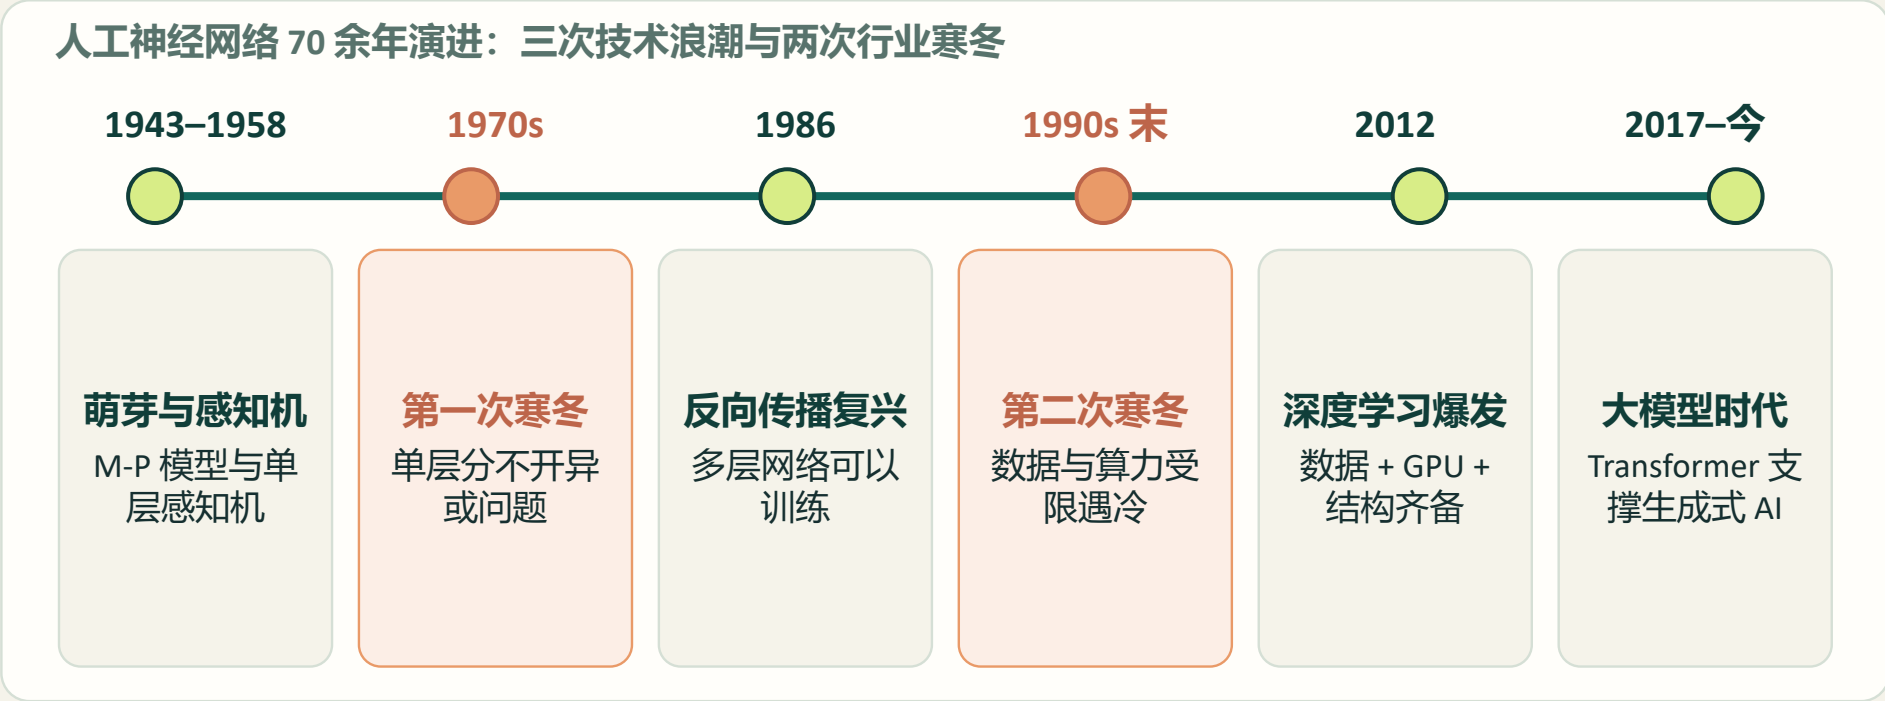
训练大型网络需要 GPU、调参周期与监控维护；如果简单方法测试效果已达标，就是更划算的选择

要点 没有“最好”的模型，只有最贴合任务、数据条件和合规要求的选择。

为什么 80 年前的方法现在才爆发

03

历史与发展：三次浪潮



一条核心规律：思想往往早于时代，真正让技术落地的是“算法改进 + 大规模数据 + 足够算力”同时凑齐。

要点 神经网络并非一夜冒出的新词，它走过了三次浪潮与两次寒冬的反复检验。

第一次浪潮与寒冬：感知机的直线困境

1943 M-P 抽象神经元模型

McCulloch 与 Pitts 提出首个用数学和逻辑电路模拟神经元的模型，证明简单单元可以执行逻辑运算

1958 单层感知机诞生

Rosenblatt 造出能从样本里自动调权重分类的感知机，媒体一度以为机器很快能像人一样思考

1969 异或难题与第一次寒冬

Minsky 与 Papert 在专著中指出单层感知机只会画一条直线，连“两个条件恰好不同为真”的异或问题都切不开，研究经费随后大幅退潮

出处：McCulloch & Pitts (1943); Rosenblatt (1958); Minsky & Papert (1969), Perceptrons.

要点 单层网络能力有限、早期宣传又过度乐观，引发了第一次研究退潮。

第二次浪潮与寒冬：会算了但算不动

突破 1986 反向传播算法普及

Rumelhart、Hinton 与 Williams 系统展示了用反向传播训练多层网络的威力

加上隐藏层后，前面切不开的“异或”和弯曲分类边界终于能够学会了

遇冷 1990 年代末为什么又冷了

当时的个人电脑算力太弱、可用数字化样本太少

层数一超过三四层，用 Sigmoid 反向传递的误差就越来越微弱，网络训不动

同期支撑向量机（SVM）、随机森林在中小表格数据上更稳更快，抢走了主流风头

出处：Rumelhart, Hinton & Williams (1986), Learning representations by back-propagating errors, Nature.

要点 有了训练方法还不够，算力、数据量和深层训练稳定性的缺口，带来了第二次寒冬。

2012 年突破：三大条件同时齐备

01 海量互联网数据

千万级标注图片、全网文本、亿级交易日志出现，喂饱了需要大量样本的深层网络

02 GPU 并行算力

原本用于游戏渲染的显卡擅长同时做几千次加减乘除，把过去数周的训练缩短到几小时

03 结构与算法改进

ReLU 激活函数、随机丢弃（Dropout）等方法解决深层梯度衰减，让几十上百层网络能稳定收敛

2012 年 ImageNet 竞赛上，深度网络 AlexNet 将错误率从约 26% 降至 15%，“深度学习”随即成为主流。

出处：Krizhevsky, Sutskever & Hinton (2012), ImageNet Classification with Deep Convolutional Neural Networks, NeurIPS.

要点 深度学习不是全新发明，而是数据、GPU 算力和训练技巧在 2012 年形成合力。

常见网络家族：不同数据用不同结构

MLP 多层感知机（全连接）

特点：每层节点与下一层全相连
擅长：表格字段（如收入、负债、指标）
局限：直接吃长文章或高清大图时参数爆炸

CNN 卷积神经网络

特点：用小窗口扫过局部并逐层拼合
擅长：图片识别、单据票据、医学影像
举例：先看局部笔画边缘，再认出整张发票

RNN / LSTM 循环神经网络

特点：把上一步的记忆传给下一步
擅长：时间序列、语音波形、短句顺序
局限：句子一长容易遗忘开头，训练难并行

Transformer 注意力架构（2017—今）

特点：用“注意力”直接看任意两词的关联
擅长：长文本理解、多模态与大语言模型
优势：可大规模并行训练，是当代大模型基石

出处：Vaswani et al. (2017), Attention Is All You Need, NeurIPS.

要点 现代神经网络已经分化出专攻表格、图像、序列与长文本的多个专业家族。

从传统网络到生成式人工智能

过去 判别式任务为主

给一张图判断是不是猫，给一条评论判断是积极还是消极

输出是有限的标签或一个风险分数

现在 生成式大模型

以 Transformer 为基石，根据上文预测下一个最合理的词，续写摘要、邮件与代码

背后依然是巨量参数在海量语料上的统计学习与对齐微调

理解大模型的常见盲区：为什么会“一本正经胡说八道”（幻觉）

大模型学的是“什么样的回答在语言上最合理”，并不内置实时财务核查能力。金融报告、合同条款与数据引用必须由人回到原始来源核实。

要点 大模型是超大规模神经网络的延续；它生成流畅答案，但不自动保证事实正确。

从输入和输出来理解跨行业应用

应用方向	常见输入信息	常见输出形式	典型生活或工作场景
图片与视觉识别	像素矩阵（照片、扫描件）	物体类别、文字框位置	人脸核验、发票票据自动录入
语音识别	一段音频波形	对应的文字记录	客服电话自动转写与质检
文本理解与生成	一段或多篇文字	分类标签、摘要或答复	公告舆情、研报要点提取
风险与行为预测	多维交易或客户记录	风险评分或核查提示	盗刷预警、授信辅助参考

不同任务的数据形态与错误代价不同，不能把某一领域的效果直接套用到另一领域。

要点 看懂任何 AI 应用，先问清“输入送什么、输出吐什么”。

金融场景一：实时交易反欺诈

业务痛点

银行卡和移动支付每秒有成千上万笔交易，盗刷团伙手法不断翻新，人工盯防和固定规则总是慢半拍

送进网络的信号

单笔金额、交易时段、设备指纹位置跳跃与近期消费偏离度

为什么适合神经网络

能在毫秒级同时交叉捕捉上百个行为特征之间的隐蔽组合（例如“深夜+异地新设备+小额试探后大额转出”）

落地核心权衡：误拦好人 vs 漏放坏人

阈值设太严会频繁拦截正常客户刷卡导致流失；设太松则会承担真实盗刷损失。通常对高分交易先触发短信确认或人工复核，而非一律直接封卡。

要点 反欺诈追求的不是“100% 自动判案”，而是在毫秒响应和错判成本之间做权衡。

金融场景二：信用风险评估与审批

场景与输入 消费贷、信用卡与小微企业授信

输入涵盖征信记录、收入与银行流水、现有负债、多头借贷迹象及行为轨迹

当输入包含非标准化流水描述或复杂交互特征时，神经网络能提供额外补充区分度

行业约束 为什么金融很少单靠“纯黑箱”直接拒贷

金融监管和消费者保护通常要求说明“为什么拒绝这份申请”

结构化信用表上，决策树/逻辑回归评分卡往往已经很强且理由透明

实践中常以可解释模型打底，或配合事后归因工具一起使用，并由人工兜底

记住第 16 页的选型原则：模型复杂不等于适合合规审查；重要授信决策必须可复核、可说明。

要点 信用审批不只是追求预测分数准，还要满足可解释、可追溯和公平性审查。

金融场景三：非结构化信息处理

01 单据与财报识别

用视觉网络与 OCR 读取营业执照、流水截图与发票，把扫描图片变成结构化数字

02 公告新闻与研报分析

从海量上市公告、债券募集书和舆情评论里提取风险提示与违约先兆

03 客服与投顾语音质检

把理财销售录音转成文字，核查是否漏读风险提示语或出现夸大承诺话术

图 / 声 / 文原始资料 → **深度学习提取结构化信号** → **并入风控或投研工作台**

要点 神经网络在金融里很有价值的用法，是把图片声音长文转化成结构化信号。

金融场景四：智能客服与投研问答助手

常见架构 检索公司知识库 + 大语言模型整理答复

用户提问后，先从经过审核的制度、产品说明书或研报库中找出相关段落

再交由大模型把多段资料整理成通顺易懂的自然语言回答，附带原文引用

落地底线 必须设定的四道保护护栏

客户隐私与未公开内幕数据先脱敏，不随意传入外部公共模型

禁止模型脱离知识库自由发挥给出具体买卖建议

涉及销户、投诉、高风险业务时转接人工坐席

保留对话日志与引用来源，方便事后抽查和定责

要点 大模型做金融助手的关键，是“先检索权威依据再组织语言”，绝不能空口编造。

金融场景五：市场预测的诱惑与陷阱

为什么大家总想用它猜股价

股票行情、资金流、宏观与新闻同时影响市场，关系高度非线性，看起来正好适合复杂神经网络

现实为什么极难（与识图截然不同）

信噪比极低：随机消息和情绪波动常淹没信号，模型容易把巧合当规律

对手盘博弈：一个赚钱规律一旦被很多人发现并交易，规律很快就会失效

规律会漂移：去年的宏观与流动性环境变了，去年学到的参数今年可能反亏

严正提示：在公开可及的数据上，历史回测曲线漂亮不等于实盘能稳定盈利；本课程案例与原理均不构成任何投资建议。

要点 图像里的“猫”一百年后还是猫，金融市场里的规律却会随着参与者博弈而随时改变。

金融场景落地的四道关卡

关卡 1 数据合规与隐私

是否获得客户明确授权？是否剔除不该使用的个人隐私与敏感属性？外部接口是否安全？

关卡 2 历史偏差延续

如果过去人工审批存在地域、年龄或群体偏见，神经网络会不加分辨地学进去并放大

关卡 3 黑箱可解释性

高风险决策不能只报一个分数，需要知道主要受哪些特征驱动，以便审核人员复核和向客户解释

关卡 4 上线后效果漂移

经济周期切换、用户结构变化或黑灰产换招数后，模型准确度会悄悄下滑，必须持续监测与更新

要点 金融业务里，上线不是终点；合规、公平、可解释和持续监测决定模型能活多久。

商科视角：检验 AI 项目的四个追问

第 1 问 到底在预测什么

目标是预测“历史审批是否通过”还是“客户未来是否违约”？定义差一步，整批标签全用错

第 2 问 赢过简单基线了吗

对比简单规则、逻辑回归或决策树，在未见过的测试集上真带来了多少业务收益？

第 3 问 错一次代价谁承担

误放和误杀哪一个损失更大？阈值设在哪里、最坏情况下的风控上限是多少？

第 4 问 出事谁复核、怎么改

有没有人工申诉与复核通道？发现模型失灵时能不能立刻降级回人工或旧规则？

要点 以后在职场作为业务或管理角色评估 AI 方案，抓牢这四个问题就能避开大多数坑。

05

案例：信用卡申请审批辅助

先明确要解决的问题

业务场景 银行每天收到大量信用卡申请

需要合理安排初审排队与审核人员的工作重点

教学目标 预测是否会通过既有审批流程

根据申请时已经获得的资料，给出参考分数，辅助审核人员安排初筛

使用方式 辅助提示并由人工拍板

最终是否发卡，必须由审核人员结合银行现行规定与具体核实情况决定

声明：本案例中的申请人、样本字段、权重数值和审批结果均为教学虚构，不代表任何真实银行的审批规则。

要点 应用设计的第一步不是选模型，而是把“模型帮谁、辅助做什么决定”写清楚。

先分清两种不同的问题

要问的问题	实际在预测什么	必须准备什么历史答案	本案例是否采用
申请能否通过历史审批	按照过去审批标准是否会批	历史审批结果：通过或未通过	采用：模拟审批
客户未来是否会违约	发卡之后规定期限内是否逾期违约	发卡后的后续真实还款记录	不采用：缺还款记录

为什么绝不能把两套标签混用

历史审批结果只反映过去审批员的决定（且没有为被拒客户记录后续还款情况），不能直接当作“未来是否违约”的答案。

要点 问题和历史答案必须一一对齐；拿过去的审批决定当未来违约答案是常见错误。

准备什么样的样本

输入信息 申请时已经获得的信息

例如申请人的月收入水平、现有负债收入比、历史逾期次数

对应答案 对应的历史审批结果

每一条历史样本都有明确的已知记录：通过（1）或未通过（0）

样本数量 足够覆盖不同情况的记录

要有足够多的通过与未通过样本，并留出一部分专门用于后续独立检验

数据合规前置要求

动手建模前，必须先明确数据来源、客户授权范围和个人信息脱敏保护措施；案例中的字段仅作教学说明，不代表实际银行全部审批维度。

要点 建模只能使用“做决定那一刻已经拿到”的合规信息，不能把事后才知道的信息混进输入。

从样本到模型的五步流程

1 检查样本 → 2 整理与缩放 → 3 划分数据 → 4 训练模型 → 5 检验结果

01–02 清洗检查并统一尺度

核查缺失与异常值，把收入、负债比和逾期次数缩放到同一尺度（只用训练集计算）

03–04 划分集合并在训练集学习

切分训练、验证与测试集，在训练集里通过反向传播调整参数降低损失

05 在未见样本上独立检验

用完全没参与调参的测试样本检查准确率与两类错误情况，观察是不是死记硬背

要点 建模不是把表丢进去点“运行”，清洗、只用训练集缩放和独立检验决定了结果可信度。

模型输出什么与算例演示

输出如何解读

分数较高：模型根据历史样本判断“通过审批”的可能性较高

分数较低：模型判断通过的可能性较低

重要限制：分数仍可能出错，只作辅助提示，不替代审批规定和人工审核

口径说明：右侧用第 6 页单神经元直算示意；互动页三层网络会先做 0–1 归一化并自动训练权重，两处权重不直接对照

算一算：沿用第 6 页单神经元，代入两份虚构申请（权重为教学虚构）

z = 0.2 × 月收入 − 0.05 × 负债比(%) − 1 × 逾期次数 + 0.5 ， 分数 = σ(z)

申请甲（收入 12 千元、负债比 20%、逾期 0 次）： z = 0.2×12 − 0.05×20 − 0 + 0.5 = 1.9 → 分数约 87%

申请乙（收入 6 千元、负债比 60%、逾期 1 次）： z = 0.2×6 − 0.05×60 − 1 + 0.5 = −2.3 → 分数约 9%

要点 神经网络给出的是一串可调参数算出来的分数，不是绝对的真假结论。

预测错误会带来什么影响

模型预测判断	历史或实际应有结果	在业务上需要关注的代价	建议的业务应对方式
预计通过（偏高）	实际不应通过	低资质申请可能被放行，后续产生不良或需要额外复核成本	设定稳健复核线，高风险边界必须人工二次核验
预计未通过（偏低）	实际可以通过	合格的优质客户被延误甚至流失，带来体验投诉与业务损失	保留人工申诉与复审通道，不能机械一键拒批

只看总体判断正确的百分比远远不够，必须拆开看这两类错误各自发生了多少、背后业务代价谁更大。

要点 评估分类结果不能只盯总体准确率，要看清“误放”和“误杀”分别有多贵。

如何检查模型是否可用

01 独立测试集体检

在训练和调参时完全没有见过的申请样本上检查准确率与各类错判比例

02 对比简单基准线

拿它和“简单几条业务规则”或“逻辑回归/决策树”同台比较，确认神经网络真带来了增值

03 分群体公平核查

按不同年龄段、区域或职业分组检查误拒率，排查是否存在明显不合理差异

04 上线后持续跟踪

经济景气或申请客群结构变化时，原有表现可能悄悄变差，需要定期重检和校准

要点 检查可用性要过四关：没见过的样本、简单基线对照、分群体检查、上线后持续跟踪。

历史决定里的偏差与完整设计思路

警惕：模型会把过去的人为偏差“学成规矩”

神经网络学的是历史审批结果里的规律；如果过去的审批存在偏见，模型会一并继承并延续下去

有些字段虽然容易采集（如住址邮编、特定背景标签），却可能隐含歧视风险，不应直接送进审批模型

01 明确问题

定清预测什么、谁来用

写明人工审核边界

02 准备数据

确保合法来源与去敏对齐

让标签和提问保持一致

03 训练检验

做独立测试并权衡两错

对比基线与群体差异

04 投入使用

保留人工复核与纠错通道

持续监测上线后效果漂移

要点 应用设计的闭环：先定人机分工与问题边界，再谈训练调参，最后用制度兜住偏差风险。

神经网络的优势与局限

06

认识局限、回顾与课堂互动

优势 它为什么受欢迎

能从足够多的样本中学习复杂的非线性组合关系

能直接处理图片、语音、长文本等非结构化信息

从经典分类扩展到大语言模型，具备强大的通用信息整理能力

局限 使用时必须清醒之处

高度依赖数据数量、质量与训练调参方式

预测可能出错，生成式系统还会出现一本正经的幻觉

内部权重众多，单次判断往往难以直接用简单规则说清理由

数据更多或网络更深，并不自动保证业务效果更好

要点 看清能力边界，不神化人工智能，也不低估它在非结构化任务上的效率。

使用模型时，别忘了背后的人

01 个人信息保护

数据涉及客户收入、交易与信用隐私时，必须关注采集授权、脱敏存储和接口安全

02 影响公平评估

模型分数关系到信贷额度、保险定价或求职筛选，要持续排查对不同人群的不合理差异

03 责任主体清晰

算法只是工具不能背锅；对个人影响重大的金融决定，必须有明确的负责机构和人工复核人

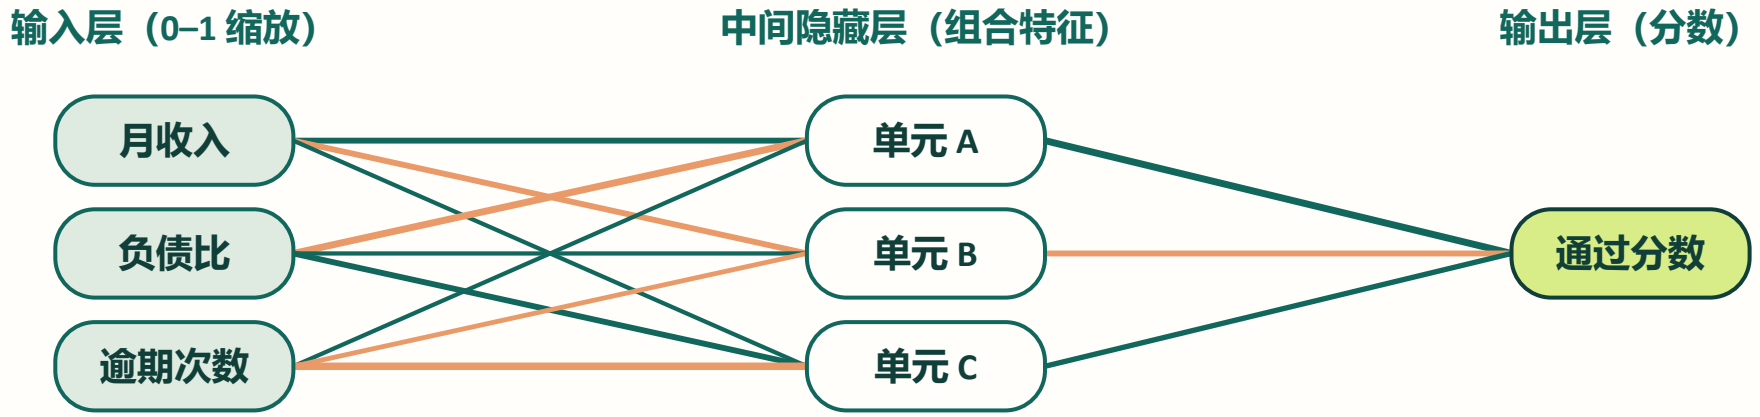
04 上线持续纠偏

建立申诉机制与定期体检制度，一旦发现系统性误判能够及时回退规则并修正

要点 技术只是手段，围绕“数据合规、公平、人工复核和责任归属”的制度设计同样关键。

课末互动预告：亲手训练一个三层网络

稍后切屏演示的 3 → 3 → 1 信用卡审批互动网络结构



前半段“观察”：看看没学之前怎样

先用初始模型测试示例 A 与示例 B，记住此时为什么两份迥异申请分数却差不多（约 54% 与 56%）

后半段“学习”：训练 1 轮与 50 轮

观察 12 条虚构历史样本如何驱动反向传播改写绿色/橙色连接权重，看训练后分数与损失的变化

要点 接下来我们会把前面讲的归一化、隐藏层、损失和反向传播都在网页里点出来看。

本课回顾

01 机制细节

神经元先加权再非线性压缩；多层隐藏单元自动组合特征；归一化与激活函数决定了训练稳不稳

02 学习过程

监督学习用预测与答案的平方误差算出损失，反向传播顺着连接把所有权重调向误差更小的地方

03 历史与架构

经历两次寒冬后因数据、GPU 算力与 ReLU 等改进在 2012 年爆发，并分化出 CNN、RNN 与 Transformer

04 场景与取舍

反欺诈、信用评估、非结构化资料提取与智能问答各有边界；股价预测极易过拟合，不盲目迷信复杂模型

要点 先明确问题与合法数据，再用合适方法训练、拿新数据检验，并留出人工复核。

理解人工智能应用的四个问题

01 它要解决什么问题

预测目标定义清晰吗？是预测过去审批习惯，还是预测未来真实违约？

02 它使用什么数据

数据合法合规吗？是否存在历史偏见、事后穿越或尺度未统一？

03 如何知道它是否可靠

在未参与训练的数据上表现如何？比简单基线强多少？错判代价算清了吗？

04 谁来使用并承担责任

业务人员能看懂辅助提示吗？有人工复核、申诉纠错和上线监测机制吗？

明确问题 → 准备数据 → 训练模型 → 独立检验 → 人工复核 → 持续监测

接下来切到互动网页，用虚构信用卡审批案例现场观察并训练模型。