大数据金融

文本分析

从文字中发现信息

原理思路、应用场景与金融案例

文字中有什么信息

商品评论
用户喜欢什么、不满意什么

新闻报道
近期发生了什么、哪些话题受到关注

问卷回答
人们提出了哪些意见

金融文本
客户反馈、公司公告、市场评论

要点 同样是一段文字，可能包含事实、观点、情绪和建议。

面对大量文字时的困难

1 数量太大

一条评论可以人工读完；上万条逐条读需要大量时间。

2 表达太多

相似意思可能有不同说法同一个词也可能有不同含义

3 一直在变

人们关注的问题会变化，需要定期更新观察。

要点 文本分析不是替代阅读，而是先整理、筛选、归纳，再把重要内容交给人细读。

什么是文本分析

定义

文本分析：利用计算机辅助处理文字，从中提取与问题有关的信息。

常见文本类型

商品评论　新闻报道　问卷回答　金融文本

文字 → 整理和分析 → 可供使用的信息

例如：从大量客户留言中归纳常见问题。

要点 输入是文字，输出是可用的信息；结果怎么解释、怎么用，仍然需要人判断。

文本分析能回答哪些问题

经常提到什么?
词频、关键词

大家在讨论哪些事?
主题或话题

表达了什么态度?
积极、消极、中性等情绪分类

哪些内容相似?
相似文本或问题归组

要点 “大家讨论收费”说的是话题；“大家对收费不满”增加了态度判断。

本课的学习目标

1 理解文字如何变成可分析的信息

2 认识关键词、主题和情绪分析的基本思路

3 了解语义相似与词向量的基本想法

4 看到金融研究中文本分析是怎样用的

5 看懂一个文本分析应用是怎样设计的

6 知道分析结果的用途和局限

本课重点是理解概念和应用，不要求编程或推导模型；公式只是帮助理解少数核心思路。

要点 不要求编程，也不要求推导公式。

02

从文字到可分析的信息

文本分析的一般流程

明确问题 → 选择文本 → 整理文本 → 提取信息 → 检查结果 → 实际使用

方法服务于问题

分析方法要服务于问题。
流程是帮助理解的基本框架。

结果回到原文

结果要回到原文检查。
实际工作可能反复往返——发现误判后，重新整理文本或调整方法。

要点 方法服务于问题，结果回到原文检查；实际工作会反复往返。

第一步：明确问题

以银行客户反馈为例：

宽泛问题
客户对服务有什么看法?

具体问题
最近一个月的客户反馈主要涉及哪些服务问题?

可能输出
常见话题，以及各话题对应的反馈示例。

要点 先确定对象、时间和结果形式，再决定收集什么文字。

第二步：选择合适的文本

文本来源
评论、客服记录、新闻、公告等。

时间范围
一周、一个月，或某个事件发生前后。

分析单位
一条评论、一篇新闻，或公告中的一段话。

使用范围
确认数据使用权限，减少不必要的个人信息。

数据来源会影响结论：一个平台的评论，只能直接反映该平台被纳入分析的评论。

要点 公开信息也要遵守适用的使用规则。

第三步：整理文本

01 删除明显重复的记录和无关广告。
02 检查缺失内容、乱码和时间信息。
03 去除不必要的个人身份信息。
04 保留可能影响理解的否定词、标点和上下文。

清洗不是越多越好

“不满意”中的“不”、引号以及表情都可能影响语义；如何处理取决于任务和方法。

要点 清洗要保留可能影响理解的否定词、标点和上下文。

中文分词：把文字切分成单位

原句

银行服务速度很快

一种切分

银行 | 服务 | 速度 | 很 | 快

- 分词帮助一些方法统计词语。
- 词怎么切，会影响后续结果。
- 不同工具处理中文时，不一定都采用同一种分词方式。

要点 中文词语之间通常没有空格；分词把连续文字切成可处理的单位。

分词歧义与新词

南京市长江大桥
一种切法：南京市 / 长江大桥
另一种切法：南京 / 市长 / 江大桥

乒乓球拍卖完了
一种切法：乒乓球拍 / 卖完了
另一种切法：乒乓球 / 拍卖 / 完了

词典没收录的新词会被切碎
例如“科创板”可能被切成“科创 / 板”。

要点 切法不同，统计结果就不同；需要按领域补充词典。

金融行话与网络用语

说法	在股吧里的意思	态度
满屏都绿了	A 股绿色表示下跌	消极
今天又吃面了	亏钱	消极
又被割韭菜	散户被收割、亏损	消极
准备抄底	认为价格已低、准备买入	偏积极（预期）
利好 / 利空	对股价有利 / 不利的消息	积极 / 消极

还有谐音、缩写、中英混写

比如“yyds”。通用词典不懂这些行话，金融文本需要领域词典。

要点 金融文本需要领域词典；注意中国股市红涨绿跌，与很多海外市场相反。

让计算机处理文字

思路一：统计词频
统计哪些词出现了，各出现几次。

思路二：结合上下文
结合上下文，把词转成一组数字。

文字变成数字：一个最简单的例子——不同的表示方式，保留的信息和丢掉的信息各不相同。

词表（共 6 个词）

银行　服务　速度　很　快　慢

银行服务速度很快
→ (1, 1, 1, 1, 1, 0)

银行服务速度很慢
→ (1, 1, 1, 1, 0, 1)

括号里的每个数，对应词表里的一个词：出现几次就写几，没出现写 0；只记次数，不记词的顺序。

要点 计算机不能直接处理文字，要先把文字转换为可计算的形式。

词频：哪些词经常出现

03

关键词、主题、情绪与语义

反馈一
“办理速度很快。”

反馈二
“办理过程顺利，速度很快。”

反馈三
“办理时间太长，速度需要改进。”

“办理”和“速度”反复出现
说明它们可能与讨论内容有关——但相同词在不同句子中可能表达不同态度：这里的“速度”既出现在表扬中，也出现在抱怨中。

要点 词频帮助快速了解常见词，是起点不是结论。

词频的一个简单公式

词频（TF）

词频（TF） = 某个词在一篇文本中出现的次数 ÷ 该文本的总词数

假设一篇文本切分后有 10 个词，“服务”出现 2 次

“服务”的词频 = 2 ÷ 10 = 0.2

词频越高，说明这个词在这篇文本里越常出现。

逐符号说明

TF：英文 Term Frequency 的缩写，意思是“词频”

出现次数：这个词在这篇文本里出现了几次

总词数：这篇文本切分后一共有几个词

÷：除号；TF 是一个比例，取值在 0 到 1 之间

采用按总词数归一化的一种词频定义；本页不要求手算，只理解比例的含义。

要点 计算之前需要先确定词如何切分、总词数是否包含停用词等。

高频词不一定是好关键词

假设收集了 10 篇关于银行服务的短文：

“银行”在每篇文章中都出现
虽然常见，却不容易区分各篇内容。

“排队”只在少数讨论办理速度的文章中出现
更可能帮助识别这类文章。

有辨识度的词，不一定就是出现次数最多的词
关键词要结合分析任务理解；这里比较的是一组文档内部的区分能力，罕见词也可能是错别字或无关内容。

要点 “排队”并非在任何场景下都比“银行”重要。

TF-IDF：怎样衡量词的辨识度

TF-IDF

TF-IDF ＝ 词频 TF × 逆文档频率 IDF

×：相乘。TF 和 IDF 都大，TF-IDF 才大

TF-IDF 衡量统计上的区分度，不自动等于词语的真实重要性；实际应用可能采用平滑等不同变体。

IDF

IDF ＝ $\log_{10}$（文档总数 ÷ 出现该词的文档数）

IDF：逆文档频率。词出现在越少的文档里，IDF 越大

$\log_{10}$：以 10 为底的对数；比值越大结果越大

假设共 10 篇短文；某一篇有 10 个词，“银行”出现 3 次，“排队”出现 2 次：

词	出现该词的文档数	IDF	TF	TF-IDF
银行	10 篇	$\log_{10}(10 \div 10) = 0$	0.3	$0.3 \times 0 = 0$
排队	2 篇	$\log_{10}(10 \div 2) \approx 0.70$	0.2	$0.2 \times 0.70 = 0.14$

要点 “银行”出现得更多，TF-IDF 却是 0；“排队”更有区分度。

从关键词到主题

一组虚构反馈中可能出现的词：

常见词语	归纳出的主题
排队、等待、窗口	**办理速度**
收费、扣款、手续费	**费用问题**
态度、解释、沟通	**服务体验**

主题帮助我们归纳

这些文字大致在讨论什么；自动分析得到的词组也需要结合原文，由人检查和命名。

要点 主题通常由多个相关词语共同体现。

主题模型的基本想法

01 多篇文本中共同反复出现的词，可能指向一个话题。
02 一篇文本可以同时涉及多个话题。
03 模型帮我们发现规律，话题是否合理，要人来检查。
04 LDA 是一种常见的主题模型，本课只了解思路。

一条反馈

“排队太久，而且工作人员解释不清”

虚构示例：同时涉及办理速度与服务体验。

主题配比（示意）

这条反馈 = 0.6 × 办理速度 + 0.4 × 服务体验

办理速度、服务体验：两个主题；0.6、0.4 为各自比重，相加等于 1（100%）

=、+：按比重混合；主题模型（如 LDA）给每条文本算出这样一组比重

数字为虚构示意。

要点 模型给出的主题不是预先保证正确的答案，解释时要回看原文。

情绪分析：表达了什么态度

虚构文本	初步判断
“办理很顺利，服务不错。”	**积极**
“等了很久，体验不好。”	**消极**
“今天去办理了业务。”	**中性**
“这个结果……算了。”	**不确定**

分类方案由任务决定

可以使用这四类，也可以设置更细的类别；对于语义不清或态度混合的文本，不必强行分类。

要点 情绪分析尝试判断文本中表达的态度。

情绪分析有哪些常见思路

情感词典
按“满意”“担心”这类词，判断文本的态度。

分类模型
从已标注的样本里，学出判断规律。

大模型辅助
结合任务说明和上下文，给出分类或摘要。

情绪得分公式

情绪得分 = (积极词个数 – 消极词个数) ÷ 总词数

例：“办理很顺利，服务不错”切成 5 个词，积极词 2 个，消极词 0 个

得分 = (2 – 0) ÷ 5 = 0.4，偏积极

得分大于 0 偏积极，小于 0 偏消极；等于 0 需回看原文（无情绪词或正负词抵消）。

积极词、消极词：词典里已标好态度的词，如“顺利”“不错”（积极）、“太慢”“担心”（消极）。

要点 三种方法各有适用条件，结果都要检查；词典方法需注意否定、语境和行业用语。

为什么需要看上下文

- “服务**好**。”——通常表达积极态度。
- “服务**不太好**。”——“好”前面有否定，意思变了。
- “这效率可真‘高’，排了两个小时。”——可能是反讽。

误判示例

只数单个词，可能看不出整句话的态度。

按公式：“服务 / 不太 / 好”共 3 个词，词典只数到积极词“好”

得分 = (1 − 0) ÷ 3 ≈ 0.33，被误判为偏积极

否定、反讽、前后文和表达对象都会影响判断。

要点 模型要允许不确定，也要人工复核。

否定、程度与转折

词典方法的两个盲区：程度与转折。

说法	语气上的变化
非常好	程度加强
有点好	程度减弱
不太好	否定，转为消极
并非不好	双重否定，偏积极但较弱

转折句：“虽然业绩增长，但是现金流紧张”——后半句往往是重点，整体偏消极。

若给词语配权重（如 ×2、×0.5）也只是示意，不能当成真实语气。

要点 只数词个数，读不出语气的轻重与转向。

词袋的盲点

同样是说股价变动，换个说法，词袋给出的相似度可能完全不同：

例一：“上涨”与“走高”

词表 [上涨, 走高]

“上涨”→ (1, 0)；“走高”→ (0, 1)

余弦相似度 = 0

例二：“股价上涨”与“股价走高”

词表 [股价, 上涨, 走高]

(1, 1, 0) 与 (1, 0, 1)

余弦相似度 = 1 ÷ (√2 × √2) = 0.5

只因为两句都有“股价”

要点 词袋只认字面，不认近义。

用上下文认识一个词

> *“You shall know a word by the company it keeps.”*
>
> —— 看一个词常和谁一起出现，就知道它是什么意思。
>
> J. R. Firth, 1957

词的二维示意 · 示意图，不是真实计算结果

填空：“今天股价___了 3%”——常见填法：上涨、走高、拉升、下跌、跳水。



A、B 语境相近彼此靠近（反义词也如此）；C、D 离 A、B 较远。

要点 词向量把常在相似语境出现的词放得近；“距离近”不等于“意思相同”，不能直接判断情绪。

从词到句的语义相似

例一：同一类问题

“排队太久了” vs “等了一个小时才办完”
没有共同词 → 词袋相似度为 0
但说的是同一类问题

例二：用词重合 ≠ 态度相同

互动页第 03 条：“这次说明清楚，我比较满意”
互动页第 04 条：“公告没有解释清楚，我不太满意”
词袋相似度 0.471，态度却相反

语义表示能找到“换了说法的同一件事”；大模型背后也是这类思路的延伸，但仍要回到原文核验。

要点 语义相似不等于词袋相似；任何结果都要回到原文核验。

不同分析方法回答不同问题

分析方法	主要回答	示例输出
关键词	哪些词较有代表性?	“排队”“手续费”
主题归纳	主要讨论哪些事?	办理速度、费用问题
情绪分析	表达了什么态度?	积极、消极、中性
文本相似	哪些内容较接近?	将相似投诉归为一组
语义相似	意思相近但用词不同的文本	把不同说法的同类投诉归为一组

方法可以组合使用

先按主题归纳，再观察各主题下的态度；“费用”是话题，“对费用不满”是对该话题的态度。

要点 不同方法回答不同问题，可以组合使用。

04

应用案例：股吧评论情绪观察

案例背景与设计

研究问题

一只股票的讨论区中，最近一周的评论表达了哪些态度？

应用设计分五步：

01 明确一周内的观察范围。
02 选择符合使用要求的评论。
03 清理明显无关、重复或缺失的记录。
04 判断每条评论的态度。
05 汇总并抽查结果，供进一步阅读。

观察对象：选定讨论区、时段内的评论；目的：整理讨论态度；评论与数据均为虚构。
实际采集前应确认平台规则与授权；保留必要时间信息，避免收集不需要的个人信息。

要点 本例只研究样本评论的表达，不讨论如何买卖股票。

准备分析样本

设想选择一周内某讨论区的评论：

分析单位
一条评论作为一个分析单位。

记录内容
记录评论文字和发表日期。

重复处理
明显广告、无关记录和重复内容按事先约定处理。

人数提醒
同一人可能多次发言，评论数量不等于人数。

转发、引用与真正的重复抓取并不完全相同；案例假设文本已获允许使用，本页不展示真实用户或真实评论。

要点 评论数量不等于人数；重复处理要结合目的。

为评论标注态度

虚构评论	示例判断
“新产品的消息让我有些期待。”	**积极**
“公告没有解释清楚，我不太满意。”	**消极**
“公司今天发布了公告。”	**中性**
“这表现可真‘稳’，一天跌了这么多。”	**消极，需结合语境**
“消息看起来不错，但我仍然担心后续进展。”	**态度混合，不确定**

判断的是文本里表达的态度，不是公司的实际经营情况。

课末互动讲稿将用同一组样本，现场对比简单词典与语境规则的差别。

要点 否定、反讽、混合态度都要结合语境判断。

汇总结果：积极评论占比

积极评论占比

积极评论占比 = 积极评论条数 ÷ 纳入统计的评论总条数

虚构例子：8 条评论，积极 3 条、消极 2 条、中性 2 条、不确定 1 条。

积极评论占比 = 3 ÷ 8 = 37.5%

分母是全部 8 条评论，包括“不确定”的那 1 条；分子和分母都要说清楚。

	积极	消极	中性	不确定	合计
条数	3	2	2	1	8
占比	37.5%	25%	25%	12.5%	100%

积极评论条数：被判为“积极”的评论有几条；纳入统计的评论总条数：参与统计的全部评论（含“不确定”）。

要点 8 条评论仅用于演示计算，不足以代表真实讨论区；口径不同，结果不能直接比较。

结果要回到原文检查

结果出来以后，必须回到原文检查——四个动作：

1 分层抽查
从积极、消极、中性和不确定类别中分别抽查。

2 重点检查
检查否定、反讽、混合态度和被引用的内容。

3 记录错误
对照分析规则与原文记录常见错误

4 调整重来
必要时调整规则或方法，再重新检查。

“涨得可真稳，跌了这么多”可能被简单词典中的“稳”误导——人工抽查就是为了抓这类错。

要点 检查少量样本不能保证所有分类正确，也不自动证明结果代表全部投资者。

怎样理解与使用结果

怎样理解

它描述的是被纳入统计的评论，不是所有投资者。
评论多的人可能影响结果；相同观点也可能被重复发布。
情绪表达与真实行为可能不同。
情绪变化与股价变化可能同时出现，不能由此直接断定因果。

怎样使用

帮助研究者定位需要进一步阅读的评论和话题。
比较同一统计口径下不同时段的讨论变化。
结合公告、新闻和其他信息核对背景。
保留统计范围、分类方法与检查记录。

比较时要注意来源、时间段、样本数量和分类规则是否一致。

要点 结果是帮助筛选和观察的线索，不能单凭评论情绪作出投资判断。

金融文本从哪里来

05

金融研究中的文本分析

公司公告与年报 | 财经新闻 | 社交媒体与股吧 | 央行与政策文件

文本 → 计数或打分 → 指标 → 对照金融数据 → 人工核验

应用一：银行客户反馈

问题： 客户最近集中反映哪些服务问题？
文本： 经过授权和适当处理的客户反馈。
方法： 按办理速度、收费、服务体验等归类
用途： 辅助定位需要进一步核查的服务环节

应用二：阅读公司公告

问题： 一份较长公告中有哪些值得关注的变化或风险？
文本： 公司公开发布的公告。
方法： 定位段落、提取关键词、辅助生成摘要。
用途： 帮助读者更快找到需细读的内容。

要点 不同来源回答不同问题；结果都要与金融数据对照并人工核验。

金融领域需要自己的词典

研究者发现：通用情绪词典里的“负面”词，在年报语境中很多并不表达负面意思。

英文词典的例子

哈佛心理学词典把 tax（税）、cost（成本）、liability（负债）、capital（资本）标为“负面”
但这些词在上市公司年报中很大一部分并不表达负面意思

中文类比

年报里的“负债”“风险提示”“减值测试”是常规表述
不能直接当消极词

于是他们按年报语境编制了金融专用词典——金融领域需要自己的词典。

出处：Loughran, T., & McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65.

要点 通用词典的“负面”在年报语境里不一定是负面；金融文本需要领域词典。

媒体语气与市场

媒体悲观情绪能否量化？它与市场价格、成交量有何关系？

指标构造

统计《华尔街日报》“Abreast of the Market”专栏中悲观类词语的比例，构造媒体悲观指标。

市场反应

悲观程度高时，市场价格随后往往承压，之后部分回归。

成交量

异常高或异常低的悲观程度，都伴随较高的成交量。

专栏文字 → 悲观词比例 → 媒体悲观指标 → 对照价格与成交量

出处：Tetlock, P. C. (2007). Giving Content to Investor Sentiment: The Role of Media in the Stock Market. *The Journal of Finance*, 62(3), 1139–1168.

要点 媒体语气可以量化，但它反映的可能是短期情绪，而不是基本面。

用报纸计数编指数

最简单的计数方法，也能做成研究指标：

方法

统计主流报纸中同时出现“经济”“政策”“不确定”三类词语的文章，按文章总数标准化

形成经济政策不确定性（EPU）指数，并用人工审读样本检验计数结果

发现

指数在战争、金融危机、重大选举等时期明显上升。

报纸文章 → **三类词同时出现** → **按文章总数标准化** → **EPU 指数** → **人工审读检验**

出处：Baker, S. R., Bloom, N., & Davis, S. J. (2016). Measuring Economic Policy Uncertainty. *The Quarterly Journal of Economics*, 131(4), 1593–1636.

要点 只要设计严谨并经人工校验，再简单的计数也能形成有影响力的研究指标。

股票论坛讨论有没有信息

股票论坛的讨论有没有信息含量?

研究设计

收集 Yahoo! Finance 和 Raging Bull 上约 45 家公司的股票讨论帖。

波动与成交量

发帖量有助于预测之后的波动

帖子中的意见分歧伴随更高的成交量

收益预测

对股票收益的预测作用虽有统计显著性，但经济意义很小。

论坛发帖 → **发帖量与意见分歧** → **对照波动、成交量、收益**

出处：Antweiler, W., & Frank, M. Z. (2004). Is All That Talk Just Noise? The Information Content of Internet Stock Message Boards. *The Journal of Finance*, 59(3), 1259–1294.

要点 讨论热度不等于能赚钱；相关不等于因果；本课内容不构成投资建议。

大模型可以怎样辅助文本分析

06

大模型、注意事项与小结

分类整理
按指定类别整理评论。

话题概括
概括一组文本中的主要话题。

段落提取
从长文本中提取与问题相关的段落。

摘要辅助
帮助生成摘要，但重要信息仍需对照原文核实。

使用提醒
大模型是一种可用于文本任务的工具，不保证每次分类或摘要都正确；给工具的任务说明、输入材料和检查方式都会影响结果。本课不展开模型训练或提示词技巧。

要点 大模型是工具，结果仍要回看原文核实。

使用文本分析时需要注意什么

数据范围
来源是否合适，能代表哪些文本？

理解偏差
是否误读了否定、反讽或上下文？

使用权限
是否有权使用文本是否涉及个人信息

结果解释
统计结果能回答什么，不能回答什么

特别注意
公开可见不等于可以无限制收集和使用。涉及非公开信息、个人信息或敏感内容时，应先确认适用要求和工具的数据处理方式，再决定能否使用；不随意将敏感原文输入外部工具。

要点 结果是线索，要结合原文和其他证据。

本课小结

文本分析帮助我们从大量文字中提取信息。

词频、关键词、主题、情绪分析回答不同问题

设计应用要考虑：**问题、文本、方法、结果、检查和使用**。

结果是进一步判断的依据之一，需要结合原文和其他证据。

问题 → **文本** → **方法** → **结果** → **检查** → **使用**

接下来切到互动页，用同一批评论现场演示。